



TOBB ETÜ
Ekonomi ve Teknoloji Üniversitesi

TOBB EKONOMİ VE TEKNOLOJİ ÜNİVERSİTESİ

Bilgisayar / Yapay Zekâ Mühendisliği

BİL 495 — YAP 495

Project Proposal

Proje Önerisi

Kapsamlı proje teklifi — onaylanmış konu üzerine kurulan dönem sözleşmesi

Proje Adı	AgentLens
Takım Üyeleri	Anıl Özişler, İrem Özdemir, Yiğit Yıldız, Arda Günaydın, Yusuf Mert Usta
Danışman	-
Akademik Dönem	2025-2026 Yaz Dönemi
Teslim Tarihi	21.06.2026

1. Problem Tanımı ve Motivasyon**2. Önceki Çalışmalar / Literatür**

- 2.1. MAST: Çoklu Ajan Sistemleri Başarısızlık Taksonomisi
 - 2.1.1 Metodolojik Yaklaşım
 - 2.1.2 Temel Hata Kategorileri
 - 2.1.3 Hata Modları Dağılımı
 - 2.1.4 Kritik Bulgular ve Mimari Karşılaştırma
- 2.2. Kolektif Akıl Yürütme ve Bilgi Dağılımı Sorunları (Li ve ark., 2026)
 - 2.2.1. Zihin Teorisi Çöküşü (Theory of Mind Collapse)
 - 2.2.2. Performans Uçurumu ve Ölçeklenebilirlik
- 2.3. Literatür Sentezi: Bilgi Asimetrisi ve Araçlar
- 2.4. MAS Dayanıklılığı İçin İyileştirme Stratejileri
 - 2.4.1. Taktiksel Yaklaşımlar
 - 2.4.2. Yapısal Stratejiler ve Eşleştirme
- 2.5. Sonuç ve Gelecek Projeksiyonu

3. Çözüm Yaklaşımı ve Yöntem

- 3.1. Önerilen Çözümün temel fikri
- 3.2 Sistem Bileşenleri Ve Teknik yaklaşım
- 3.3 Sistemin Temel Algoritmik İşleyişi
- 3.4 Mimari paradigma
- 3.5 Kullanılacak Yöntem Ve Araçlar

4. Mimari Taslağı**5. Hedef Kullanıcı, Kapsam ve Başarı Kriterleri**

- 5.1 Hedef Kullanıcılar
- 5.2 Kapsam
 - Proje Kapsamında Yer Alan Özellikler (In-Scope)
 - Proje Kapsamı Dışında Yer Alan Özellikler (Out-of-Scope)
- 5.3 Başarı Kriterleri

Başarı Kriteri 1: Hata Tespit Performansı

Başarı Kriteri 2: Hata Türü Sınıflandırma Başarısı

Başarı Kriteri 3: Açıklanabilirlik Yeteneği

Başarı Kriteri 4: İşlem Süresi

6. Çalışma Planı ve İş Bölümü**7. Riskler ve Önlemler****8. Beklenen Çıktılar**

- 8.1 Çalışan Prototip
- 8.2 Performans Değerlendirme Sonuçları
- 8.3 Veri Kümesi
- 8.4 Teknik Dokümantasyon
- 8.5 Proje Raporları
- 8.6 Proje Web Sitesi
- 8.7 Açık Kaynak Depo

9. Kaynaklar

1. Problem Tanımı ve Motivasyon

Günümüz yapay zeka sistemlerinin karmaşık problemleri çözebilmesi için kimi zaman tek bir büyük dil modeli yetersiz kalabilmektedir. Bu yetersizlik sonucunda alanında uzman olan birden fazla ajanın beraber çalışması gereksinimi doğabilir. Bu gereksinim sonucunda oluşan birden fazla ajanın iletişimde olduğu sistemlere çok ajanlı sistemler (MAS) denir. Çok ajanlı sistemler araştırma yapma, içerik üretme ve değerlendirme gibi işlevlerle yazılım geliştirme, bilimsel araştırma ve otomasyon gibi alanlarda büyük katkı sağlamaktadır.

Bu sistemlerin nasıl oranlarda ve nasıl başarısız olduğunu, sistematik bir şekilde inceleyen güncel ve en kapsamlı çalışmalardan biri, 2025 yılında yayımlanan MAST (Multi-Agent System Failure Taxonomy) çalışmasıdır. Projemiz doğrultusunda hem güncel hem de kapsamlı bir taksonomi sağlaması sebebiyle, temel alacağız. MAST verilerine göre incelenen sistemlerin başarısızlık oranları %41 ile %87 arasında değişkenlik göstermektedir. MAST çok ajanlı sistemlerin (MAS) başarısız olduğu durumları 3 ana kategoride inceler. Bunlar sistem tasarım problemleri (System Design Issues), ajanlar arası yanlış hizalanma (Inter-Agent Misalignment) ve görev doğrulama (Task Verification) olarak 3 kategoriye ayırır. Bu kategoriler sırasıyla 44.2%, 32.3% ve 23.5% olarak dağılım sağlamaktadır. Başarısızlıkların önemli bir oranının ajanların bireysel yetersizliklerinden değil, görev devretme ve bağlam aktarma yaptıkları iletişim ve koordinasyon katmanından geldiği görülebilmektedir.

Mevcut araçlar her ne kadar bu hataları kayıt altına alabilse de iletişim katmanında hangi adımda ne tür bir uyumsuzluk sebebiyle başarısızlık oluştuğunu otomatik olarak tespit edip raporlayan bir araç bulunmamaktadır. Amacımız bu aracı oluşturarak çok ajanlı sistemleri kullanan, araştıran veya geliştiren yazılım mühendisleri, araştırmacılar ve ekiplere yardımcı olabilecek bir dış araç sağlayabilmek.

2. Önceki Çalışmalar / Literatür

Çoklu Ajan Sistemleri (MAS), büyük dil modellerinin (LLM) kolektif zeka, görev ayrıştırma, performans paralelleştirme ve bağlam izolasyonu gibi yeteneklerini bir araya getirerek tekli ajanların kısıtlarını aşmayı hedefleyen gelişmiş mimarilerdir. Bu sistemler, uzmanlaşmış modellerin tartışma ve iş birliği yoluyla karmaşık problemleri çözebileceği "sosyal akıl yürütme" ortamları sunar. Ancak güncel literatür, MAS yapılarının vaat edilen performans kazanımlarının çoğu zaman sınırlı kaldığını göstermektedir (Cemri ve ark., 2025). Tekli ajanlara kıyasla MAS performansındaki bu durağanlık, sistemik hata kalıplarının derinlemesine analizini zorunlu kılmaktadır. Bu rapor, MAST taksonomisi ve HIDDEN-BENCH bulguları üzerinden MAS dayanıklılığını engelleyen temel darboğazları değerlendirmektedir.

2.1. MAST: Çoklu Ajan Sistemleri Başarısızlık Taksonomisi

Cemri ve ark. (2025) tarafından geliştirilen MAST (Multi-Agent System Failure Taxonomy), MAS başarısızlıklarını ampirik bir temelde sınıflandıran ilk kapsamlı çalışmadır.

2.1.1 Metodolojik Yaklaşım

Çalışma, "Grounded Theory" (Gömülü Kuram) yaklaşımını kullanarak 7 farklı MAS çerçevesinden toplanan 1600'den fazla trace analizi üzerine inşa edilmiştir. 150 trace üzerinde yapılan uzman incelemeleri sonucunda 0.88'lik yüksek bir "inter-annotator agreement" (κ) skoruna ulaşılmıştır. Ölçeklenebilirliği sağlamak adına kullanılan OpenAI o1 modeli tabanlı "LLM-as-a-Judge" boru hattı, insan uzmanlarla 0.77 oranında uyum sergileyerek doğrulanmıştır.

2.1.2 Temel Hata Kategorileri

MAS hataları üç ana kategoride (Failure Categories - FC) toplanmıştır:

1. Sistem Tasarımı Hataları (FC1): Mimari kararlar, yetersiz rol tanımları ve hatalı state yönetiminden kaynaklanan hatalar.
2. Ajanlar Arası Hizalanma Sorunları (FC2): İletişim kopuklukları ve koordinasyon eksiklikleri.
3. Görev Doğrulama Sorunları (FC3): Kalite kontrol süreçlerinin yetersizliği veya hatalı çalışması.

2.1.3 Hata Modları Dağılımı

Aşağıdaki tablo, 1642 trace analizi sonucunda tespit edilen 14 hata modunun (FM) dağılımını ve aşamalarını göstermektedir:

Hata Modu	Yüzde (%)	Gerçekleştiği Aşama
1.3 Adım Tekrarı (Step Repetition)	15.7	Yürütme (Execution)
2.6 Akıl Yürütme-Eylem Uyuşmazlığı	13.2	Yürütme
1.5 Sonlandırma Koşullarından Habersiz Olma	12.4	Post-Execution
1.1 Görev Tanımına Uymama	11.8	Pre/Execution
3.3 Hatalı Doğrulama (Incorrect Verification)	9.1	Post-Execution
3.2 Eksik Doğrulama (No/Incomplete Verification)	8.2	Post-Execution
2.3 Görev Sapması (Task Derailment)	7.4	Yürütme
2.2 Açıklama İstememe	6.8	Pre/Execution
3.1 Erken Sonlandırma (Premature Termination)	6.2	Post-Execution
1.4 Konuşma Geçmişi Kaybı	2.8	Yürütme
2.1 Konuşma Sıfırlama (Conversation Reset)	2.2	Yürütme
2.5 Diğer Ajanın Girdisini Görmezden Gelme	1.9	Yürütme
1.2 Rol Tanımına Uymama	1.5	Pre-Execution
2.4 Bilgi Saklama (Information Withholding)	0.8	Yürütme

2.1.4 Kritik Bulgular ve Mimari Karşılaştırma

Analizler, "Adım Tekrarı" (%15.7) ve "Akıl Yürütme-Eylem Uyuşmazlığı" (%13.2) gibi modların en yaygın başarısızlık nedenleri olduğunu göstermektedir. Özellikle MetaGPT ve ChatDev mimarileri karşılaştırıldığında, MetaGPT'nin sistem tasarımı (FC1) ve hizalanma (FC2) hatalarında %60-68 oranında daha dirençli olduğu, ancak görev doğrulama (FC3) hatalarında ChatDev'e kıyasla 1.56 kat daha fazla başarısızlık sergilediği görülmüştür. Bu durum, Standart İşletme Prosedürlerine (SOP) dayalı mimarilerin hizalanmayı artırırken doğrulama disiplininin ödün verdiğini (trade-off) kanıtlamaktadır.

2.2. Kolektif Akıl Yürütme ve Bilgi Dağılımı Sorunları (Li ve ark., 2026)

Li ve ark. (2026) tarafından sunulan HIDDEN-BENCH analizi, bilginin ajanlar arasında dağıtıldığı senaryolarda MAS'ın kolektif akıl yürütme kapasitesini incelemektedir.

2.2.1. Zihin Teorisi Çöküşü (Theory of Mind Collapse)

MAS başarısızlıklarının psikolojik kökeninde "Zihin Teorisi" çöküşü yatmaktadır. Ajanlar, muhataplarının bilgi durumlarını veya eksikliklerini modelleyememektedir. Bu durum, ajanların diğerlerinin bildiği ancak henüz ifade etmediği bilgiler hakkında akıl yürütememesi olan "örtük bilgi asimetrisi" (latent information asymmetry) çıkmazına yol açmaktadır.

2.2.2. Performans Uçurumu ve Ölçeklenebilirlik

HIDDEN-BENCH verileri, bilginin dağıtılmasının maliyetini çarpıcı şekilde ortaya koymaktadır: Tam bilgiye sahip tek bir ajanın başarı oranı %80.7 iken, aynı bilgi parçalandığında MAS başarı oranı %30.1'e düşmektedir. Bu performans kaybı, grup boyutu arttıkça koordinasyon yükü ve bilgi asimetrisi nedeniyle daha da derinleşmekte; model ölçeğinin artırılması bu yapısal sorunu çözmemektedir.

2.3. Literatür Sentezi: Bilgi Asimetrisi ve Araçlar

MAS dayanıklılığı için önerilen AESOP, SentinelAgent, AgentAuditor ve FLARE gibi araçlar, MAST taksonomisindeki kritik boşlukları doldurmak üzere konumlandırılmaktadır. Örneğin, SentinelAgent ve AgentAuditor doğrudan FC3 (Görev Doğrulama) hatalarını denetlemek amacıyla tasarlanmıştır. HIDDEN-BENCH'te tanımlanan "örtük bilgi asimetrisi", MAST'taki "Bilgi Saklama" (FM-2.4) ve "Açıklama İstememe" (FM-2.2) hatalarının temel nedenidir. Ajanlar, "Hidden Profile" (Gizli Profil) paradigması gereği, kritik bilginin zaten paylaşıldığını veya bilindiğini varsayarak keşif sürecini durdurmakta; bu da paylaşılan kısıtlı kanıtlar üzerinde erken uzlaşıya (premature convergence) yol açmaktadır. GraphTracer gibi grafik tabanlı yapılar ve yapılandırılmış iletişim protokolleri, bu bilgi kaybını önleyerek konuşma geçmişinin korunmasını (FM-1.4) ve bilginin asimetrik dağıldığı ortamlarda tıkanıklıkların aşılmasını hedeflemektedir.

2.4. MAS Dayanıklılığı İçin İyileştirme Stratejileri

MAS performansını artırmak için stratejiler, tespit edilen hata kategorileriyle doğrudan eşleştirilmelidir.

2.4.1. Taktiksel Yaklaşımlar

Rol ve Hiyerarşi Tanımları: ChatDev vaka çalışmasında, CEO ajanına son söz hakkı verilmesi gibi iş akışı düzenlemeleri başarı oranını %9.4 artırmıştır.

Öz-Doğrulama (Self-verification): AG2 senaryolarında uygulanan çok ajanlı doğrulama döngüleri, başarı oranında %15.6'lık bir artış sağlamıştır (Cemri ve ark., 2025).

2.4.2. Yapısal Stratejiler ve Eşleştirme

Belirsizlik Miktarının Belirlenmesi (Uncertainty Quantification): Bu strateji, ajanların düşük güven duydukları bilgiler için açıklama istemesini sağlayarak FC2 (Ajanlar Arası Hizalanma) hatalarına karşı birincil savunma hattını oluşturur.

Çok Seviyeli Doğrulama (Multi-level Verification): Sadece sözdizimsel değil, anlamsal ve görev odaklı kontrollerin entegrasyonu FC3 (Görev Doğrulama) hatalarını minimize eder.

Bellek Yönetimi: MemGPT (Packer ve ark., 2024) gibi yaklaşımlar, bağlam kayıplarını önleyerek FC1 (Sistem Tasarımı) kategorisindeki FM-1.4 hatalarını engellemektedir.

Topolojik Dönüşüm: Ajan yapısının DAG'dan döngüsel grafiklere dönüştürülmesi, hata tespit ve düzeltme döngülerini (self-correction) etkinleştirmektedir.

2.5. Sonuç ve Gelecek Projeksiyonu

MAS alanındaki analizler, "Ölçeklendirme Hipotezi"nin (Scaling Hypothesis) aksine, daha güçlü LLM'lerin tek başına sistemik başarısızlıkları çözemeyeceğini göstermektedir. Başarısızlıkların kökeni, modellerin ham yeteneklerinden ziyade hatalı organizasyonel tasarımlarda ve bilgi entegrasyonu süreçlerindeki yapısal zayıflıklarda yatmaktadır. Gelecekteki MAS araştırmalarının, ajanların birbirlerinin bilişsel durumlarını simüle edebildiği yeteneklerine ve örtük bilgi asimetrisini proaktif olarak yönetebilen standartlaştırılmış iletişim protokollerine odaklanması gerekmektedir. Gerçek kolektif zeka, ajanların sadece konuşabildiği değil, birbirlerinin neyi bilmediğini de modelleyebildiği sistemlerle mümkün olacaktır.

3. Çözüm Yaklaşımı ve Yöntem

3.1. Önerilen Çözümün temel fikri

Önerdiğimiz çözümün yaklaşımı, Çok ajanlı LLM sistemlerinde gerçekleşen ajanlar arası konuşma akışını gerçek zamana yakın takip edecek, bu konuşma adımlarını standard bir formata çevirecek ve sonrasında iki aşamalı LLM tabanlı tespit mekanizmasıyla uyumsuzlukları tespit edecek bir mimariye dayanmaktadır. Sistemin uyumsuzluk tespitiyle beraber başarısızlığın hangi adımda gerçekleştiği , taksonomide hangi uyumsuzluk türüne denk geldiği, hangi ajanlar arasında gerçekleştiği ve neden gerçekleştiğini anlaşılabilir bir şekilde raporlaması da amaçlanmaktadır.

3.2 Sistem Bileşenleri Ve Teknik yaklaşım

Sistem ajanlar arası konuşmaları **Data Collector** modülünü kullanarak izler. Bu modül çok ajanlı LLM sistemde ajan A ile ajan B arasındaki mesajları , ajanların kendilerine ait log kayıtlarını ve bu ajanlarla alakalı gerekli metadatalar bilgisini toplar. Metadatalar mesajı göndermiş olan ajan, mesajı almış olan ajan, konuşmanın sırası, zaman bilgisi, varsa araçların çağırma bilgisi, gerçekleştirilen aksiyonun bilgisi veya görevin bağlamı olabilir.

Data Collector tarafından toplanan ham veri **Raw Trace Storage** içine saklanır. Bu bileşen ileride formatlama sırasında çıkabilecek bir hata durumunda ya da sistemin başka bileşenleri üzerinde değişiklik yapılma ihtimalinde eski konuşmalar tekrar işlenip formatlanabilir. Bu bileşen projenin ilerideki aşamalarında yapılacak değerlendirme hata analizi ve sistemin geriye dönük incelenebilmesi için de önem taşır.

Ham sohbet verileri saklandıktan sonra modelin anlayacağı formatlanmış veriye işlenmesi için **Data Formatter** modülüne verilir. Bu adım farklı sistemlerin üretebileceği farklı logları standard bir formatta modülümüzün anlayabileceği hale getirmek içindir. Konuşmalar burada formatlı ortak bir JSON konuşma şemasına indirgenir. Bu şema ajan isimleri, roller, mesaj içeriği, konuşma sırası, global görev, varsa araçların çağırılma bilgisi ve gerçekleştirilen aksiyonun detaylarını içerir. Bu modül sonucu elimizde tutarlı bir girdi yapısı oluşur.

Formatlanan veri **Conversation Window Builder** modülüne aktarılır. Ajanlar arası uyumsuzlukların açıkça anlaşılabilmesi için şu anki mesajımız ve konuşma geçmişine ihtiyaç duyarız. Böylelikle bağlam üzerinden uyumsuzluk daha açık anlaşılabilir. Bu modül formatlanmış veriyi ve bu verilerden oluşan hafızayı yönetmekle görevlidir. Formatlı konuşma geçmişi ve güncel mesaj birleştirilerek sonraki adıma verilir. Bu kombinasyon verinin önceki konuşma bağlamında değerlendirilmesini sağlar.

Formatlı verilerden oluşan konuşma geçmişini tutacak olan **Formatted Data Storage**, conversation window builder modülünden gelecek olan yeni sohbetleri depolamanın yanında aynı zamanda ihtiyaç duyulduğunda yine aynı modele formatlı konuşma geçmişini sağlamakla görevlidir. Konuşma geçmişinin gerektiği durumlarda tekrar verinin formatlanmasıyla zaman kaybedilmemesi için önem taşır.

Sistemin yapay zeka tabanlı tespit modülü iki aşamadan oluşur. Conversation window builder tarafından üretilen kombinasyon ilk aşama olarak **Stage 1: Anomaly Detection** modeline gelir. Bu modelde gelen girdinin normal mi yoksa şüpheli mi olduğunu belirler. Bu adım hızlı ve maliyeti azaltmak için bir ön kontrol mekanizması olarak tasarlanmıştır. Böylece her adımda büyük ve maliyetli bir LLM kullanılması engellenmiş olur. Bu aşamada temel aldığımız veri setlerindeki veriler veya kendi ürettiğimiz sentetik veriler kullanılarak few-shot prompting yöntemi kullanılacaktır. Model önceden önceden hazırlanmış normal ve anormal konuşma örnekleri verilecek, verilen bu örneklerle yeni gelen konuşma penceresi için ikili sınıflandırma yapılacaktır. Çıktı normal veya anormal biçiminde olacaktır. Modelin karar güvenini göstermesi için anomali skoru üretilmesi planlanmaktadır.

Stage 1: Anomaly Detection modeli için hedefimiz MAST çalışmasının sonuçlarındaki recall değerlerine olabildiğince yaklaşmaktır. Bu değerlerle orantılı bir şekilde bir miktar yanlış pozitifler tolere edilebilir görülmektedir. Sistemin birinci aşamada gözden kaçırabileceği olası uyumsuzluklar ikinci aşamaya ulaşamayacağından tespit edilememe ihtimali vardır. Bu sebepten dolayı bu modelin yüksek yakalama oranına sahip olacak şekilde tasarlanması amaçlanmaktadır. Model, bu aşama sırasında MAST store verilerini kullanabilir.

İlk aşamada normal olarak değerlendirilen konuşma pencereleri doğrudan Dashboard / Logs bileşenine iletilir. Bu sayede sistem sadece başarısız durumların raporlarını değil, normal konuşma akışını da sunar. Normal kayıtların görünürlüğü, daha sonra yanlış negative incelenmesi, model performans değerlendirmesi ve genel sistem analizi açısından önemlidir.

Stage 1 sonucunda şüpheli algılanan kombine veriler ikinci aşamaya iletilir. **Stage 2: Failure Analysis** modeli daha güçlü bir LLM tabanlı analiz modelidir. Bu model şüpheli değerleri doğrulamanın yanı sıra aynı zamanda başarısızlığın olduğu noktayı, sebebini, hangi sınıflandırmada olduğu ve ilgili ajanlar gibi bilgileri raporu üretecek Report generator modeline iletecektir. MAST veri setinden ve oluşturulan sentetik verilerden oluşan etiketli örnekler, sistemin farklı başarısızlık türlerini öğrenmesi ve benzer durumları tanıyabilmesi için kullanılacaktır.

Stage 2 modeli içerisinde retrieval destekli dinamik few-shot seçimi yaklaşımı kullanılması planlanmaktadır. Bu yaklaşımda MAST veri setinden elde edilen başarısızlık örnekleri, kapsam içindeki her başarısızlık modunu temsil edecek şekilde bir örnek havuzunda tutulacaktır. Yeni bir şüpheli konuşma penceresi geldiğinde, bu örneğe anlamsal olarak en yakın geçmiş örnekler embedding tabanlı retrieval mekanizması ile dinamik olarak seçilecek ve Stage 2 modelinin prompt'una few-shot örnek olarak eklenecektir. Böylece model her yeni vaka için sabit bir prompt ile karar vermek yerine, o vakaya özgü ve ilgili başarısızlık tipi örneklerini içeren bağlama duyarlı bir prompt ile analiz yapabilecektir. Bu yaklaşım özellikle çok ajanlı sistemlerde ortaya çıkan hataların bağlama bağımlılığı dolayısıyla seçilmiştir. Aynı başarısızlık modu farklı konuşma bağlamlarında

farklı biçimlerde anlam kazanabileceğinden, statik örnek seçimi yerine dinamik retrieval ile daha tutarlı ve doğru sınıflandırma yapılması hedeflenmektedir.

İkinci aşama modelinin oluşturduğu analiz sonucu **Report Generator** modülüne aktarılır. Bu modülde analiz standard ve anlaşılabilir bir rapor formatına dönüştürülür. Raporun structured output formatında üretilmesi planlanmaktadır. Böylece çıktı hem insan hem de başka sistemler tarafından işlenebilir durumda olacaktır.

Son aşama olarak üretilen raporlar **Dashboard / Logs** bileşenine aktarılır. Bu bileşen sistem tarafından sağlanan, konuşma detaylarının incelenebildiği katmandır. Bu katmanda normal etiketlenen konuşmalar, başarısızlıkların analizi, raporlar görünebilir. Aynı zamanda projenin değerlendirme süreci için kullanılacak veriler sağlamaktadır.

3.3 Sistemin Temel Algoritmik İşleyişi

1. Çok Ajanlı LLM Sistemi içerisinde Ajan A ile Ajan B arasında mesajlaşma gerçekleşir.
2. Ajanlar arasındaki mesajlar, log kayıtları ve metadata bilgisi Data Collector tarafından yakalanır.
3. Toplanan ham konuşma verisi Raw Trace Storage içerisinde saklanır.
4. Ham konuşma verisi işleme hattına aktarılır ve Data Formatter tarafından standart JSON formatına dönüştürülür.
5. Formatlanan veri Formatted Data Storage içerisinde saklanır.
6. Conversation Window Builder, Formatted Data Storage'dan konuşma geçmişini okur ve güncel mesajla birleştirerek analiz penceresi oluşturur.
7. Stage 1: Anomaly Detection Model, oluşturulan analiz penceresini few-shot prompting yöntemiyle analiz ederek normal veya şüpheli sınıflandırması yapar ve anomali skoru üretir.
8. Normal olarak değerlendirilen örnekler doğrudan Dashboard / Logs bileşenine aktarılır.
9. Şüpheli olarak işaretlenen örnekler Stage 2: Failure Analysis Model'e iletilir.
10. Stage 2, retrieval destekli dinamik few-shot seçimi yaklaşımıyla MAST Store'dan ilgili failure örneklerini çeker ve bu örnekleri prompt'una ekleyerek uyumsuzluk türünü, başladığı konuşma adımını ve ilgili ajanları belirler.
11. Stage 2 çıktısı Report Generator modülüne aktarılır ve structured output formatında rapor üretilir.
12. Üretilen rapor Dashboard / Logs bileşenine iletilerek kullanıcıya sunulur ve değerlendirme süreci için kayıt altına alınır.

3.4 Mimari paradigma

Önerilen mimari, her bileşenin tek bir sorumluluğa sahip olduğu modüler bir pipeline yapısı üzerine inşa edilmiştir. Bu tasarım sayesinde herhangi bir bileşen değiştirildiğinde diğer bileşenler etkilenmez ve sistem farklı çok ajanlı yapılarla kolaylıkla entegre edilebilir. Sistem ayrıca ajanların iç işleyişine müdahale etmediği için log kayıtları üzerinden çalıştığından, izlenen sistemi değiştirmeye gerek kalmadan dışarıdan bağlanılabilir bir yapı sunar. Bu mimari paradigmanın seçilme nedeni, performans ve açıklanabilirlik arasında denge kurmaktır. Tek aşamalı büyük bir LLM değerlendirme sistemi kullanılsaydı, her konuşma adımı yüksek maliyetli analiz yapılması gerekecekti. Benzer şekilde, yalnızca küçük bir sınıflandırıcı kullanılsaydı, sistemin hataları ayrıntılı açıklaması ve başarısızlık tipi seviyesinde raporlaması zorlaşacaktı. Önerilen iki aşamalı yapı sayesinde sistem, normal konuşmaları hızlıca filtrelerken yalnızca riskli durumlar için daha ayrıntılı ve maliyetli analiz gerçekleştirmektedir.


3.5 Kullanılacak Yöntem Ve Araçlar

Bileşen	Kullanılacak yöntem/teknoloji	Seçim gerekçesi
Data Collector	Python watchdog kütüphanesi (log izleme), os / pathlib (dosya yönetimi), API Interceptors, Event Listeners veya Middleware	Ajanların log kayıtlarını anlık izlemek için
Raw Trace Storage	JSON dosyası (başlangıç), seçilecek database	Ham verinin yeniden işlenebilmesi, hata analizi ve geriye dönük inceleme için
Data Formatter	pydantic (şema doğrulama), json (parse), pandas (MAST verisi işleme)	Farklı kaynaklardan gelen veriyi tutarlı standart JSON formatına dönüştürmek için
Formatted Data Storage	Seçilecek database	Formatlanmış mesajların saklanması ve Conversation Window Builder tarafından okunabilmesi için
Conversation Window Builder	Python list veri yapısı	Güncel mesajı birikmiş konuşma geçmişiyle birleştirerek Stage 1'e bağlamalı girdi sağlamak için
MAST Store	HuggingFace datasets, statik JSON dosyası, sentence-transformers (embedding), FAISS veya ChromaDB (vector store)	Few-shot örnek havuzu ve retrieval destekli dinamik örnek seçimi için

Stage 1: Anomaly Detection Model	GPT-4o-mini veya Claude Haiku API, openai / anthropic SDK, few-shot prompting	Hızlı ve düşük maliyetli binary sınıflandırma; her adımda büyük LLM çalıştırmaktan kaçınmak için
Stage 2: Failure Analysis Model	GPT-4o-mini veya Claude Haiku API, openai / anthropic SDK, retrieval destekli dinamik few-shot, instructor (JSON çıktı garantisi), gerekebilecek durumlarda GPT-4o veya Claude 3.5 Sonnet	Failure type sınıflandırması, başlangıç turu tespiti ve açıklanabilir analiz üretimi için
Report Generator	jinja2 (şablon), json (structured output)	Model çıktısını hem insan hem sistem tarafından okunabilir standart rapor formatına dönüştürmek için
Dashboard / Logs	Streamlit veya Dash	Sonuçların kullanıcıya sunulması ve değerlendirme için kayıt altına alınması için
Evaluation Pipeline	scikit-learn (precision, recall, F1, confusion matrix), matplotlib / seaborn (görselleştirme)	Sistem başarımının nicel metriklerle ölçülmesi ve raporlanması için

Projenin genel kodlama süreçlerinin Python ortamında yürütülmesi, ekip içi kod paylaşımı ve ortak çalışma için bir GitHub organizasyonu kurulması, yapay zeka modellerinin geliştirilme aşamasında ise ağırlıklı olarak Google Colab kullanılması planlanmaktadır.

4. Mimari Taslağı



5. Hedef Kullanıcı, Kapsam ve Başarı Kriterleri

5.1 Hedef Kullanıcılar

Proje kapsamında geliştirilecek sistemin temel hedef kitlesi, çok ajanlı sistemlerin geliştirilmesi, değerlendirilmesi ve güvenilirliğinin artırılması üzerine çalışan araştırmacılardan ve yazılım mühendislerinden oluşmaktadır.

Birincil Kullanıcılar:

- Çok ajanlı LLM sistemleri geliştiren araştırma ve geliştirme ekipleri,
- Ajan tabanlı AI uygulamaları geliştiren yazılım mühendisleri,
- Çok ajanlı sistemlerin performans ve güvenilirliğini değerlendiren araştırmacılar.

İkincil kullanıcılar:

- Yapay zeka sistemlerinin açıklanabilirliği ve denetlenebilirliği üzerine çalışan araştırmacılar,

- Yapay zeka test ve kalite güvencesi süreçlerinden sorumlu ekipler,
- Çok ajanlı sistemler üzerinde çalışan öğrenci ve eğitimciler.

5.2 Kapsam

Proje Kapsamında Yer Alan Özellikler (In-Scope)

- MAST veri kümesinde yer alan çok ajanlı konuşma kayıtlarının işlenmesi ve analiz edilmesi,
- MAST veri kümesinin yetersiz kaldığı alanlarda sentetik veri üretim yöntemlerinin kullanılması,
- Ajanlar arasındaki iletişim akışının incelenmesi ve konuşma geçmişinin değerlendirilmesi,
- MAST taksonomisinde tanımlanan iletişim ve koordinasyon kategorisine dahil hata türlerinin otomatik olarak tespit edilmesi,
- Tespit edilen uyumsuzlukların uygun hata kategorileri altında sınıflandırılması,
- Hatanın gerçekleştiği konuşma adımının belirlenmesi,
- Tespit edilen hata için açıklayıcı ve okunabilir raporların üretilmesi,
- MAST veri kümesi üzerinde performans değerlendirmesi yapılması,
- Precision, Recall ve F1-Skoru gibi metriklerle sistem performansının ölçülmesi.

Proje Kapsamı Dışında Yer Alan Özellikler (Out-of-Scope)

- Çok ajanlı sistemlerin görev yürütme süreçlerine doğrudan müdahale edilmesi,
- Tespit edilen hataların otomatik olarak düzeltilmesi veya ajan davranışlarının yeniden planlanması,
- İnsan-ajan etkileşimlerinden kaynaklanan hataların incelenmesi,
- Görsel veya ses olarak çıktı üreten sistemlerin analizi,
- Yeni bir çok ajanlı sistem mimarisinin geliştirilmesi.

5.3 Başarı Kriterleri

Proje çıktılarının objektif biçimde değerlendirilebilmesi amacıyla ölçülebilir başarı kriterleri belirlenmiştir. Geliştirilecek sistemin başarılı kabul edilebilmesi için aşağıdaki kriterlerin karşılanması hedeflenmektedir.

Başarı Kriteri 1: Hata Tespit Performansı

Sistemin, MAST veri kümesinde yer alan örnekler üzerinde gerçekleştirilen testlerde iletişim ve koordinasyon uyumsuzluklarını tespit etmede en az 0,8 F1-Skoruna ulaşması hedeflenmektedir.

Başarı Kriteri 2: Hata Türü Sınıflandırma Başarısı

Tespit edilen uyumsuzlukların ilgili hata kategorilerine doğru atanabilmesinde en az %75 sınıflandırma doğruluğu elde edilmesi amaçlanmaktadır.

Başarı Kriteri 3: Açıklanabilirlik Yeteneği

Sistem tarafından tespit edilen her hata için:

- Hatanın gerçekleştiği konuşma adımının belirlenmesi,
- Hata türünün raporlanması,
- Hatanın neden gerçekleştiğine dair açıklama üretilmesi

beklenmektedir. Test edilen örneklerin en az %90'ında bu bilgilerin eksiksiz şekilde sunulması hedeflenmektedir.

Başarı Kriteri 4: İşlem Süresi

Bir çok ajanlı konuşma oturumunun analiz edilmesi ve raporlanması sürecinin ortalama olarak 10 saniyenin altında tamamlanması hedeflenmektedir. Böylece sistemin gerçek zamanlı veya gerçek zamana yakın senaryolarda kullanılabilmesinin önü açılmaktadır.

6. Çalışma Planı ve İş Bölümü

Bu bölümde proje süresince yürütülecek işler haftalara ayrılmıştır. Her hafta için yazılım tarafı, veri işleme tarafı ve yapay zekâ/model tarafındaki görevler paralel ilerleyecek şekilde planlanmıştır. Görevlerin yanında ilgili sorumlu üyeler belirtilmiştir. Zor ve entegrasyon açısından kritik görevlerde birden fazla sorumlu atanmıştır.

Faz 1 / Hafta 1 — Problem kapsamının netleştirilmesi ve başlangıç planı

- İki ajanlı başlangıç sistemi için kullanılacak teknolojiler araştırılır; Agent A ve Agent B'nin haberleşmesine dair ilk teknik taslak çıkarılır.
Sorumlu: İrem, Yusuf
 - İleride kullanılacak ham ve formatlanmış veri alanları incelenir; mesaj, rol, zaman damgası gibi alanları içeren ilk veri şeması taslağı hazırlanır.
Sorumlu: Yiğit
 - MAST veri seti ve hata taksonomisi incelenir; Stage 1: Anomaly Detection Model'in normal/anomali ayrımı yapabilmesi için kullanılabilecek örnekler belirlenir.
Sorumlu: Anıl
 - Stage 2: Failure Analysis Model'in üreteceği çıktılar belirlenir. Bu kapsamda failure type, explanation, evidence, structured report ve Dashboard / Logs ekran ihtiyaçları çıkarılır.
Sorumlu: Arda
 - Beklenen çıktı: Problem kapsamı, teknik kararlar, ilk veri şeması ve model çıktı taslakları.
-

Faz 1 / Hafta 2 — Ortak veri formatı ve modül arayüzlerinin belirlenmesi

- İki ajanlı konuşma ortamının kodlanmasına başlanır; Agent A ve Agent B'nin mesaj alışverişini sağlayacak temel yapı oluşturulur.
Sorumlu: İrem
 - Data Formatter için standart JSON formatı detaylandırılır; ham konuşma verisinin hangi alanlara ayrılacağı belirlenir.
Sorumlu: Yiğit
 - MAST örneklerini normal/anomalous olarak ayırmak için ilk etiketleme stratejisi belirlenir; Stage 1 için few-shot prompt yapısı tasarlanır.
Sorumlu: Anıl, Yusuf
 - Stage 2 için structured output şeması detaylandırılır; modelin failure type + explanation üretmesi için ilk prompt taslağı hazırlanır.
Sorumlu: Arda
 - Beklenen çıktı: Ortak JSON şeması, iki ajanlı ortamın kod taslağı, Stage 1 ve Stage 2 prompt tasarımları.
-

Faz 2 / Hafta 3 — İki ajanlı test ortamı ve ilk veri hattı prototipi

- Agent A ve Agent B'nin konuşabildiği basit prototip geliştirilir; Data Collector'ın mesajları yakalaması için ilk bağlantı kurulur.
Sorumlu: İrem

- Mock raw trace örnekleri üzerinden Data Formatter prototipi geliştirilir; ham mesajlar standart JSON formatına dönüştürülmeye başlanır.
Sorumlu: Yiğit
 - MAST veri setinden Stage 1 için kullanılabilecek normal ve anomalous örnekler ayıklanır; ilk few-shot örnek havuzu oluşturulur.
Sorumlu: Anıl
 - Stage 2 için MAST örneklerinden failure analysis durumları çıkarılır; bir anomali adayı için failure type ve explanation üretimi denenir.
Sorumlu: Arda, Yusuf
 - Beklenen çıktı: Çalışan iki ajanlı konuşma prototipi, Data Formatter prototipi ve ilk MAST örnek havuzu.
-

Faz 2 / Hafta 4 — Ham veri toplama ve saklama yapısının kurulması

- Data Collector geliştirilir; ham konuşma kayıtları Raw Trace Storage içerisine JSONL veya veritabanı formatında kaydedilir.
Sorumlu: Arda
 - Data Formatter'ın raw trace verisini okuyup standart formatted data üretmesi sağlanır; Formatted Data Storage için ilk kayıt yapısı oluşturulur.
Sorumlu: İrem
 - Stage 1: Anomaly Detection Model için ilk sınıflandırma denemeleri yapılır; normal/anomaly candidate ayrımı test edilir.
Sorumlu: Anıl , Yusuf
 - Report Generator için örnek structured report formatı oluşturulur; Stage 2 çıktısı olmadan mock verilerle rapor üretimi test edilir.
Sorumlu: Yiğit
 - Beklenen çıktı: Data Collector prototipi, Raw Trace Storage yapısı, Stage 1 ilk testleri ve Report Generator prototipi.
-

Faz 3 / Hafta 5 — Formatlama, konuşma penceresi ve model çalışmalarının paralelleştirilmesi

- Data Collector ve Raw Trace Storage üzerinde hata yakalama, eksik log kontrolü ve yeniden deneme akışı geliştirilir.
Sorumlu: Anıl
- Conversation Window Builder modülü geliştirilir; current formatted data ile chat history bilgisi birleştirilerek pencere çıktısı üretilir.
Sorumlu: Yiğit, Yusuf
- Stage 1 modeli iyileştirilir; few-shot prompt örnekleri genişletilir; anomali skoru üretimi için ilk eşik değerleri test edilir.
Sorumlu: İrem
- Stage 2: Failure Analysis Model için ilk çalışan prototip geliştirilir; anomali adayları üzerinden failure type + explanation çıktısı üretilir.
Sorumlu: Arda

- Beklenen çıktı: Conversation Window Builder prototipi, geliştirilmiş Stage 1 ve Stage 2 çalışan prototipleri.
-

Faz 3 / Hafta 6 — Bağlam oluşturma ve ilk model değerlendirmeleri

- Data Collector'ın farklı konuşma senaryolarını yakalaması sağlanır; Agent A ve Agent B için normal ve hatalı konuşma örnekleri üretilir.
Sorumlu: Anıl
 - Conversation Window Builder'ın sliding window mantığı iyileştirilir; farklı pencere boyutları test edilir; verilerin doğru birleşmesi sağlanır.
Sorumlu: Arda
 - Stage 1 için scoring ve threshold çalışması yapılır; yüksek recall hedefiyle false positive ve false negative durumları incelenir.
Sorumlu: İrem
 - MAST Store'dan benzer örnek getirme mantığı Stage 2 için tasarlanır; retrieved examples bilgisinin prompt içine yerleştirilmesi test edilir.
Sorumlu: Yusuf, Yiğit
 - Beklenen çıktı: Test konuşmaları, iyileştirilmiş context window, Stage 1 eşik çalışması ve Stage 2 retrieval taslağı.
-

Faz 4 / Hafta 7 — Stage 1 ve Stage 2 modellerinin güçlendirilmesi

- Data Collector ve Raw Trace Storage tarafında veri bütünlüğü testleri yapılır; mesajların eksiksiz ve sıralı kaydedildiği doğrulanır.
Sorumlu: Yusuf
 - Conversation Window Builder çıktısının Stage 1 modeline uygunluğu test edilir; gerektiğinde context formatı optimize edilir.
Sorumlu: Yiğit, Arda
 - Stage 1 modelinin performansı ölçülür; precision, recall ve F1-score için ilk sonuçlar çıkarılır; few-shot örnekleri optimize edilir.
Sorumlu: İrem
 - Stage 2 modelinde failure type sınıflandırması geliştirilir; explanation kalitesi ve evidence extraction başarısı artırılır.
Sorumlu: Anıl
 - Beklenen çıktı: Stage 1 metrikleri, iyileştirilmiş Stage 2 failure analysis çıktıları ve veri bütünlüğü test sonuçları.
-

Faz 4 / Hafta 8 — Raporlama ve görselleştirme katmanının geliştirilmesi

- Entegrasyon testleri için Data Collector'dan gerçek konuşma kayıtları sağlanır; ham veri tarafında ortaya çıkan hatalar düzeltilir.
Sorumlu: Yiğit
- Data Formatter ve Conversation Window Builder modülleri Stage 1 ve Stage 2 ihtiyaçlarına göre güncellenir.
Sorumlu: Arda, Anıl

- Stage 1 modeli sistem akışına entegre edilmeye başlanır; normal ve anomaly candidate çıktılarının yönlendirilmesi test edilir.
Sorumlu: İrem
 - Report Generator ve Dashboard / Logs prototipi geliştirilir; structured report çıktısı görselleştirilir; anomali kayıtları listelenir.
Sorumlu: Yusuf
 - Beklenen çıktı: Stage 1 entegrasyon başlangıcı, Report Generator prototipi ve Dashboard / Logs ilk ekran yüzü.
-

Faz 5 / Hafta 9 — Uçtan uca entegrasyonun başlatılması

- Multi-Agent LLM System → Data Collector → Raw Trace Storage akışı gerçek zamanlı çalışacak şekilde test edilir.
Sorumlu: Anıl
 - Data Collector'dan gelen ham verinin Data Formatter ve Conversation Window Builder üzerinden Stage 1'e doğru aktığı doğrulanır.
Sorumlu: Yusuf, Arda
 - Stage 1 modeli Conversation Window Builder çıktısıyla entegre edilir; normal/anomali ayrımının sistem içinde çalışması sağlanır.
Sorumlu: İrem
 - Stage 2, Report Generator ve Dashboard / Logs entegrasyonu yapılır; anomali adayından structured report çıktısına kadar olan akış test edilir.
Sorumlu: Yusuf, Yiğit
 - Beklenen çıktı: İlk uçtan uca çalışan prototip, gerçek zamanlı veri akışı ve Dashboard'da görünen ilk anomali raporları.
-

Faz 5 / Hafta 10 — Sistemin dış kullanıma uygun hale getirilmesi

- Data Collector farklı multi-agent sistemlerine bağlanabilecek şekilde genelleştirilir; arayüzler bağımsız hale getirilmek için düzenlenir.
Sorumlu: İrem, Anıl, Yiğit
 - Data Formatter farklı formatlardan gelen konuşma kayıtlarını işleyebilecek şekilde esnekleştirilir; input validation ve schema kontrolü eklenir.
Sorumlu: Arda
 - Stage 1 modelinin farklı görev tiplerinde çalışması test edilir; threshold ve few-shot örnekleri genel kullanıma uygun hale getirilir.
Sorumlu: Yusuf, Yiğit
 - Stage 2 ve Report Generator çıktılarının dış sistemlerde kullanılabilmesi için JSON formatı netleştirilir; Dashboard ekranı son haline getirilir.
Sorumlu: Yusuf
 - Beklenen çıktı: Modüler Data Collector, esnek Data Formatter ve dış kullanıma uygun ortak structured report formatı.
-

Faz 6 / Hafta 11 — Deneysel değerlendirme ve sistem iyileştirme

- Toplanan raw trace kayıtlarında eksik, hatalı veya sıralaması bozuk veri olup olmadığı analiz edilir; tespit edilen pipeline hataları düzeltilir.
Sorumlu: İrem
 - Conversation Window Builder kaynaklı yanlış bağlam problemleri incelenir; pencere boyutu ve içerik seçimi iyileştirilir.
Sorumlu: Yiğit
 - Stage 1 sonuçları analiz edilir; yanlış pozitif ve yanlış negatif örnekler incelenir; modelin scoring eşik değerleri güncellenir.
Sorumlu: Arda, Anıl
 - Stage 2 açıklama kalitesi değerlendirilir; failure type hataları, evidence extraction eksikleri ve Report Generatoreksikleri düzeltilir.
Sorumlu: Yusuf
 - Beklenen çıktı: Deneyisel sonuçlar, detaylı hata analizi, iyileştirilmiş Stage 1 ve Stage 2 çıktıları, güncellenmiş Dashboard.
-

Faz 6 / Hafta 12 — Final rapor, demo ve teslim

- Demo için iki ajanlı sistemin stabil çalışması sağlanır; Data Collector ve Raw Trace Storage akışı gösterime hazır hale getirilir.
Sorumlu: İrem
 - Data Formatter ve Conversation Window Builder modüllerinin demo sırasında doğru çalışması sağlanır; teknik dokümantasyon tamamlanır.
Sorumlu: Anıl
 - Stage 1 model sonuçları ve değerlendirme metrikleri final rapora eklenir; anomaly detection kısmı sunuma hazır hale getirilir.
Sorumlu: Arda, Yusuf
 - Stage 2, Report Generator ve Dashboard / Logs demo akışı hazırlanır; failure type + explanation + structured report çıktısı sunuma eklenir.
Sorumlu: Yiğit
 - Beklenen çıktı: Final rapor, final sunum, çalışan uçtan uca demo ve modüler proje çıktısı.
-

Proje Sonu Hedefi — Modüler Dağıtım

- Data Collector'ın farklı agent sistemlerine entegre edilebilmesi için wrapper veya API kullanım mimarisi dokümante edilir.
Sorumlu: İrem, Yusuf, Anıl
- Data Formatter ve Conversation Window Builder için input/output şemaları yapılandırılmış kılavuz halinde belgelenir.
Sorumlu: Yiğit
- Stage 1 modelinin nasıl çağrılacağı, hangi girdi formatını beklediği ve ürettiği anomali skorlama detayları belgelenir.
Sorumlu: Yusuf
- Stage 2, Report Generator ve Dashboard bileşenlerinin dış yazılımlara nasıl veri aktaracağı ve entegrasyon adımları açıklanır.
Sorumlu:

- Beklenen çıktı: Diğer yazılımcıların kendi çok ajanlı LLM sistemlerine entegre edebileceği modüler, açıklanabilir anomali tespit sistemi.

7. Riskler ve Önlemler

Risk değerlendirmesinde olasılık ve etki değerleri **Düşük**, **Orta** ve **Yüksek** olarak sınıflandırılmıştır.

Risk	Olasılık	Etki	Önlem	B Planı
Sistemin yalnızca bizim iki ajanlı test ortamımızda çalışması ve diğer geliştiriciler tarafından kolay kullanılamaması	Yüksek	Yüksek	Proje başından itibaren Data Collector, Data Formatter, Stage 1, Stage 2 ve Report Generator modülleri birbirinden bağımsız çalışabilecek şekilde tasarlanacaktır. Her modül için açık input/output formatı belirlenecek ve sistem belirli bir agent framework'e bağımlı kalmayacaktır.	Tam entegrasyon paketi yetişmezse sistem en azından dışarıdan JSON/JSONL konuşma kaydı alıp analiz edebilen bağımsız bir offline tool olarak sunulacaktır. Ayrıca örnek kullanım dosyaları ve entegrasyon kılavuzu hazırlanacaktır.
Data Collector'ın farklı multi-agent sistemlerinden gelen konuşma formatlarını destekleyememesi	Orta	Yüksek	Data Collector doğrudan tek bir sisteme bağlı yazılmak yerine wrapper veya adapter mantığıyla tasarlanacaktır. Farklı sistemlerden gelen mesajlar ortak bir trace formatına dönüştürülecektir.	Gerçek zamanlı bağlantı desteklenemezse kullanıcıların kendi sistemlerinden export ettikleri konuşma kayıtlarını sisteme yükleyebileceği dosya tabanlı analiz yöntemi kullanılacaktır.
Standart veri şemasının başka sistemler için yetersiz kalması	Orta	Yüksek	Başlangıçta minimum ama genişletilebilir bir JSON şeması tasarlanacaktır.	Fazladan alanlar opsiyonel yapılacaktır. Böylece farklı sistemlerden gelen eksik ama temel alanları içeren veriler de analiz edilebilecektir.
İki ajanlı test ortamının beklenenden geç kurulması	Düşük	Orta	İlk aşamada yalnızca mesajlaşma yapabilen basit bir iki ajanlı sistem kurulacaktır. Karmaşık görev çözme özellikleri sonraya bırakılacaktır.	İki ajanlı sistem gecikirse MAST veri setinden ve elle hazırlanmış mock conversation örneklerinden yararlanılarak Data Formatter, Stage 1 ve

				Stage 2 geliştirilmeye devam edecektir.
Data Collector'ın agent mesajlarını eksik veya hatalı yakalaması	Düşük	Yüksek	Mesajlarda sender, receiver, timestamp ve turn sırası gibi zorunlu alanlar kontrol edilecektir. Ham veriler Raw Trace Storage içinde saklanacaktır.	Eksik veri durumunda sistem uyarı verecek ve analiz için eksik alanları minimum şema üzerinden tamamlamaya çalışacaktır. Gerekirse hazır JSONL konuşma kayıtlarıyla test yapılacaktır.
Stage 1 modelinin çok fazla yanlış alarm üretmesi	Orta	Orta	Few-shot örnekleri dengeli seçilecek, anomaly score ve threshold değerleri test edilecektir.	Stage 1 yüksek recall odaklı tutulacak; fazla gelen yanlış alarmlar Stage 2 tarafından elenecektir.
Stage 1 modelinin gerçek anomalileri kaçırmaması	Orta	Yüksek	Recall metriği öncelikli takip edilecek, false negative örnekleri düzenli incelenecektir.	Threshold değeri düşürülerek daha fazla örneğin Stage 2'ye gönderilmesi sağlanacaktır.
Stage 2 modelinin yanlış failure type veya zayıf açıklama üretmesi	Orta	Yüksek	MAST örnekleri ve failure taxonomy prompt içine dahil edilecektir. Evidence ve explanation alanları structured output ile zorunlu tutulacaktır.	Stage 2 çıktıları manuel kontrol edilecek; gerekirse daha az failure type ile daha sınırlı ama daha güvenilir analiz yapılacaktır.
MAST veri setinin proje ihtiyacını tamamen karşılamaması	Yüksek	Orta	MAST veri seti öncelikli kaynak olarak kullanılacak, eksik kalan senaryolar belirlenecektir.	Sentetik veri üretilecektir.

Bu projedeki ana B planı, sistemin tam anlamıyla farklı framework'lere entegre edilebilir hale getirilememesi durumunda, sistemi bağımsız çalışan bir analiz aracı olarak sunmaktır. Bu durumda sistem, başka geliştiricilerin kendi multi-agent sistemlerinden aldıkları konuşma kayıtlarını JSON formatında kabul edecek; Data Formatter, Conversation Window Builder, Stage 1 ve Stage 2 üzerinden analiz ederek structured report çıktısı üretecektir. Böylece gerçek zamanlı entegrasyon veya paketleme tam olarak tamamlanmasa bile sistemin temel amacı olan ajanlar arası uyumsuzluk tespiti, failure type belirleme ve açıklanabilir raporlama işlevleri gösterilebilecektir.

Uzun vadeli hedef ise sistemin wrapper, API veya modüler kütüphane şeklinde sunulmasıdır. Bu sayede diğer yazılımcılar kendi çok ajanlı LLM sistemlerinde yalnızca mesaj kayıtlarını sisteme göndererek anomali tespiti ve açıklamalı hata raporu alabilecektir.

8. Beklenen Çıktılar

8.1 Çalışan Prototip

Projenin temel çıktısı, MAST veri kümesinde tanımlanan hata taksonomilerini temel alan ve ajanlar arası iletişim akışlarını analiz ederek uyumsuzlukları otomatik olarak tespit edip çıktı üretebilen çalışan bir prototip sistem olacaktır. Bu sistem, çok ajanlı konuşmaları giriş olarak alacak ve konuşma içerisinde meydana gelen iletişim veya koordinasyon hatalarını belirleyebilecektir.

8.2 Performans Değerlendirme Sonuçları

Proje sonunda geliştirilen sistemin performansı çeşitli deneylerle değerlendirilecek ve aşağıdaki metrikler raporlanacaktır:

- Accuracy
- Precision
- Recall
- Confusion Matrix
- Span
- F1-Skoru
- Ortalama analiz süresi

Elde edilen sonuçlar mevcut çalışmalar ve MAST veri kümesindeki referans sonuçlarla karşılaştırılacaktır.

8.3 Veri Kümesi

MAST veri kümesiyle uyumlu veya sentetik olarak üretilmiş, etiketlenmiş ajanlar arası konuşma örneklerinden oluşan veri kümesi açık kaynak olarak yayımlanacaktır.

8.4 Teknik Dokümantasyon

Proje sonunda sistem mimarisini, veri akışını, kullanılan teknolojileri ve modüllerin çalışma prensiplerini açıklayan kapsamlı teknik dokümantasyon hazırlanacaktır.

8.5 Proje Raporları

BİL 495 kapsamında aşağıdaki raporlar yazılacaktır:

- Project Proposal,
- Project Specifications,
- Analysis,
- PKE-Plan,
- High-Level Design.

8.6 Proje Web Sitesi

BİL 495 kapsamında HTTPS destekli kamuya açık, proje hakkında bilgi veren ve tüm raporları içinde bulunduran bir web sitesi oluşturulacaktır.

8.7 Açık Kaynak Depo

Tüm kaynak kodu, kurulum talimatları, kullanım kılavuzu, örnek konuşma verileri ve değerlendirme verilerini içeren GitHub deposu. Depo, başka kullanıcıların sistemi kendi MAS ortamlarında çalıştırabilmesini sağlayacak düzeyde belgelenecektir.

9. Kaynaklar

Cemri, M., Pan, M. Z., Yang, S., Agrawal, L. A., Chopra, B., Tiwari, R., Keutzer, K., Parameswaran, A., Klein, D., Ramchandran, K., Zaharia, M., Gonzalez, J. E., & Stoica, I. (2025). *Why do multi-agent LLM systems fail?* arXiv. arXiv:2503.13657v3.

Li, Y., Naito, A., & Shirado, H. (2026). Systematic failures in collective reasoning under distributed information in multi-agent LLMs. *Proceedings of the 43rd International Conference on Machine Learning (ICML)*.

Packer, C., Wooders, S., Lin, K., Fang, V., Patil, S. G., Stoica, I., & Gonzalez, J. E. (2024). *MemGPT: Towards LLMs as operating systems*. arXiv. arXiv:2310.08560.

Park, J. S., O'Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). *Generative agents: Interactive simulacra of human behavior*. arXiv. arXiv:2304.03442.

Wu, Y., Yue, T., Zhang, S., Wang, C., & Wu, Q. (2024). *StateFlow: Enhancing LLM task-solving through state-driven workflows*. arXiv. arXiv:2403.11322.