



TOBB ETÜ
Ekonomi ve Teknoloji Üniversitesi

TOBB EKONOMİ VE TEKNOLOJİ ÜNİVERSİTESİ

Bilgisayar / Yapay Zekâ Mühendisliği

BİL 495 — YAP 495

Proje Kısıt ve Etkiler Dokümanı

PKE-Plan

Plan sürümü — BİL495 sonunda teslim edilir

Proje Adı	AgentLens
Takım Üyeleri	Anıl Özişler, İrem Özdemir, Yiğit Yıldız, Arda Günaydın, Yusuf Mert Usta
Danışman	Shadi Bikas
Akademik Dönem	2025-2026 Yaz Dönemi
Teslim Tarihi	31.07.2026

1. Kullanılan Standartlar.....
 - Standart 1: GDPR (Veri Koruma Yönetmeliği) [1] ve 6698 Sayılı KVKK [2].....
 - Standart 2: ACM Code of Ethics [3] ve IEEE Code of Ethics [4].....
2. Proje Kısıtları.....
3. Beklenen Etkiler.....
 - Ekonomik Etki.....
 - Sosyal Etki.....
 - Çevresel Etki.....
 - Hukuki Etki.....
 - Sağlık Etkisi.....
 - Güvenlik Etkisi.....
4. Kaynakça.....

1. Kullanılan Standartlar

Standart 1: GDPR (Veri Koruma Yönetmeliği) [1] ve 6698 Sayılı KVKK [2]

İlgili Madde: GDPR Madde 5 (Veri Minimizasyonu ve Amaçla Sınırlılık) ve KVKK Madde 4 (Kişisel verilerin işleme şartları).

Uygulanabilirlik Notu: Çok ajanlı sistemlerin mesaj logları kullanıcıların kişisel veya hassas verilerini içerebilir. Sistemin dış LLM API'lerine (OpenAI, Anthropic) analiz için veri göndermeden önce bu verileri maskeleymesi yasal bir zorunluluktur.

Planlanan Kanıt Kaynağı: *İnceleme ve Test*. Geliştirilen veri formatlama (Data Formatter) modülündeki takma adlandırma (pseudonymization) algoritmalarının birim test raporları (unit tests) ve kaynak kod analizi ile doğrulanması.

Standart 2: ACM Code of Ethics [3] ve IEEE Code of Ethics [4]

İlgili Madde: ACM Madde 1.2 (Olası zararı en aza indirme), Madde 2.6 (İşi dürüstçe değerlendirme) ve IEEE Madde 1 (Hesap verilebilirlik ve teknik iddiaların dürüstlüğü).

Uygulanabilirlik Notu: AgentLens sisteminin "Yargıç (LLM-as-a-Judge)" modeli olarak çalışırken taraf tutmaması (algoritmik önyargı) ve kendi değerlendirmelerini (yanlış pozitif/yanlış negatif oranları) abartısız ve şeffaf bir biçimde raporlaması gerekir.

Planlanan Kanıt Kaynağı: Analiz. Sistemin tespit başarısının MAST test kümesi üzerinde elde edeceği F1-Skoru, Confusion Matrix (Karmaşıklık Matrisi), Precision ve Recall metriklerinin nicel analiz raporlarıyla sunulması.

2. Proje Kısıtları

Kategori	Tanım	Etki Alanı	Doğrulama / Kanıtlama Yöntemi
Ekonomik (API Bütçe Kısıtı)	Sistem, her konuşma penceresi için OpenAI veya Anthropic servislerine (API) çağrı yapmaktadır. Projenin akademik bağlamda kurumsal bir bütçesi olmaması, maliyetli büyük modellerin sürekli kullanımını imkansız kılmaktadır.	Kullanılabilecek LLM modellerinin kapasitesi, konuşma penceresinin uzunluğu ve anlık olarak analiz edilebilecek eşzamanlı log hacmi.	Analiz. Sadece şüpheli durumlarda Stage 2 modelinin tetiklendiğini gösteren API kullanım loglarının analizi ve maliyetin kotalar altında kaldığının gösterilmesi.

Kategori	Tanım	Etki Alanı	Doğrulama / Kanıtlama Yöntemi
Çevresel (Enerji Tüketimi)	Büyük dil modellerinin aralıksız olarak veri işlemesi sunucularda yüksek elektrik tüketimine ve buna bağlı karbon emisyonuna yol açmaktadır. Sürekli izleme yapan araçlar yüksek çevresel ayak izi bırakır.	Sistemin bulut alt yapısındaki enerji ayak izi ve çevresel sürdürülebilirliği. Mimarideki model çağırma (prompting) sıklığı.	Analiz. İki aşamalı filtreleme (Stage 1 ve Stage 2) sayesinde işlenmekten kurtarılan token (kelime) sayısının nicel olarak raporlanması ve dolaylı enerji tasarrufunun teorik hesaplaması.
Sağlık / Güvenlik (Yüksek Risk)	Sağlık (örneğin teşhis) veya finans gibi hata toleransının sıfır olduğu kritik alanlarda çalışan MAS'larda, AgentLens'in bir hatayı gözden kaçırmaması (yanlış negatif) telafi edilemez fiziksel veya maddi zararlara yol açabilir.	Sistemin doğrudan otomatik karar alıcı (decision-maker) olarak konumlandırılmaması ve arayüz üzerindeki güven düzeyi (confidence score) gösterimleri.	İnceleme. Dashboard ve üretilen raporlarda, çıktıların nihai karar mekanizması olmadığına dair sorumluluk ret (disclaimer) bildirimlerinin ve güven skorlarının incelenmesi.
Teknolojik / Sürdürülebilirlik	AgentLens'in analiz yeteneği, temel aldığı MAST hata taksonomisine bağlıdır. İleride çıkacak yeni nesil yapay zeka ajan mimarilerinde ortaya çıkabilecek yeni hata türlerini statik bir veri seti ile tanıyamayabilir.	Sistemin uzun vadeli doğruluk oranı, güncelliği ve yeni veri setlerine (framework) entegrasyon esnekliği.	Kod İncelemesi (Code Review). Referans alınan MAST veri tabanının koda gömülü (hardcoded) olmadığı, sistemin dışarıdan güncellenebilir JSON konfigürasyonlarıyla beslendiğinin doğrulanması.

3. Beklenen Etkiler

AgentLens projesi, otonom sistemlerde ortaya çıkan ve manuel olarak tespit edilmesi oldukça güç olan iletişim uyuşmazlıklarını gözlemlenebilir yaparak geniş çaplı incelemelere zemin hazırlamaktadır.

Ekonomik Etki

Sistemin yapılandırılmış raporları (structured reports), araştırma-geliştirme ve kalite güvence (QA) ekiplerinin manuel log inceleme gereksinimini ortadan kaldırmaktadır. Hata ayıklama (debugging) süreçlerindeki bu dramatik düşüş, hem işgücü ve mesai maliyetlerini azaltacak hem de endüstrideki ajan tabanlı yazılım ürünlerinin pazara çıkış süresini (time-to-market) hızlandırarak önemli bir rekabet avantajı sağlayacaktır.

Sosyal Etki

Otonom sistemlerdeki "kara kutu" probleminin şeffaflaştırılması, yapay zekanın toplumsal kabulünü doğrudan olumlu etkileyecektir. AgentLens, üretken ajanların karar süreçlerini ve aralarındaki etkileşimleri net bir şekilde açıklayarak, son kullanıcıların ve toplumun yapay zeka sistemlerine duyduğu güveni [6] uzun vadede inşa edecek ve teknolojiyle olan etkileşimi daha anlaşılır bir zemine oturtacaktır.

Çevresel Etki

Doğrudan bulut sistemleri üzerinde çalışan devasa dil modelleri (LLM), yüksek karbon emisyonuna sebep olur. AgentLens, yalnızca şüpheli durumlarda çalışan iki aşamalı filtreleme mimarisi ile GPU sunucularındaki çıkarım (inference) yükünü optimize eder. Bu yaklaşım, daha düşük enerji tüketen "yeşil (green) yapay zeka" ilkelerini destekler.

Hukuki Etki

Avrupa Birliği Yapay Zeka Yasası (AI Act) [5] başta olmak üzere uluslararası düzenlemeler, algoritmik sistemlerin "açıklanabilir" ve "insan gözetimine (human oversight)" uygun olmasını şart koşmaktadır. AgentLens, aralarındaki uyuşmazlıkları net bir adım ve kanıt dizisiyle ortaya koyarak bu hukuki gereksinimlere teknik bir altyapı sunar. Ayrıca GDPR [1] ve KVKK [2] uyumlu log maskeleyme pratikleri, veri gizliliğinin geliştirici ortamlarında standartlaşmasını teşvik edecektir.

Sağlık Etkisi

Çok ajanlı sistemler; medikal veri analizi, teşhis destek sistemleri ve hasta takibi gibi alanlarda kullanılmaya başlanmıştır. Bu ajanlar arasında yaşanabilecek bir "bilgi saklama" veya iletişim kopukluğu, yanlış teşhis gibi doğrudan insan sağlığını tehdit eden telafisi zor zararlara yol açabilir. AgentLens, bu sistemlerdeki gizli iletişim kopukluklarını proaktif olarak raporlayarak hasta sağlığını dolaylı olarak koruma altına alabilir.

Güvenlik Etkisi

Siber tehdit tespiti, otonom savunma veya acil durum lojistiği gibi güvenlik açısından kritik alanlarda çalışan MAS'larda, ajanlar arası koordinasyon hayati önem taşır. AgentLens, "hatalı görev doğrulama" gibi anomalileri tespit ederek dış denetim katmanını sunar ve güvenlik zafiyetlerinden doğabilecek operasyonel krizlerin ve kritik sistem çökmelerinin önüne geçebilir.

4. Kaynakça

- [1] European Union, "Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)".
- [2] T.C. Yasama Organı, "Kişisel Verilerin Korunması Kanunu", Kanun No. 6698, T.C. Resmî Gazete.
- [3] Association for Computing Machinery, "ACM Code of Ethics and Professional Conduct", 2018.
- [4] IEEE, "Ethical Guidelines & Policies: IEEE Code of Ethics".
- [5] European Parliament and Council, "Regulation laying down harmonised rules on Artificial Intelligence (Artificial Intelligence Act)".
- [6] High-Level Expert Group on Artificial Intelligence, "Ethics Guidelines for Trustworthy AI", European Commission.
- [7] M. Cemri, M. Z. Pan, S. Yang, L. A. Agrawal, B. Chopra, R. Tiwari, K. Keutzer, A. Parameswaran, D. Klein, K. Ramchandran, M. Zaharia, J. E. Gonzalez, and I. Stoica, "Why do multi-agent LLM systems fail?" arXiv preprint arXiv:2503.13657v3, 2025.