



TOBB ETÜ
Ekonomi ve Teknoloji Üniversitesi

TOBB EKONOMİ VE TEKNOLOJİ ÜNİVERSİTESİ

Bilgisayar / Yapay Zekâ Mühendisliği

BİL 495 — YAP 495

Project Specifications Report

Proje Spesifikasyon Raporu

Sistemin ne yapacağı: kapsam, kısıtlar, etik sorumluluklar, gereksinim listesi

Proje Adı	AgentLens
Takım Üyeleri	Anıl Özişler, İrem Özdemir, Yiğit Yıldız, Arda Günaydın, Yusuf Mert Usta
Danışman	-
Akademik Dönem	2025-2026 Yaz Dönemi
Teslim Tarihi	28.06.2026

1. Introduction.....	
1.1 Amaç.....	
1.2 Hedef Kullanıcılar.....	
1.3 Başarı Kriterleri.....	
Başarı Kriteri 1: Hata Tespit Performansı.....	
Başarı Kriteri 2: Hata Türü Sınıflandırma Başarısı.....	
Başarı Kriteri 3: Açıklanabilirlik Yeteneği.....	
Başarı Kriteri 4: İşlem Süresi.....	
2. Description.....	
2.1 Sistem Tanımı ve İşleyişi	
2.2 Ana Fonksiyonlar.....	
2.3 Out-of-Scope.....	
3. Constraints.....	
3.1 Hukuki Kısıtlar.....	
3.2 Etik Kısıtlar.....	
3.3 Çevresel Kısıtlar.....	
3.4 Ekonomik Kısıtlar.....	
3.5 Sosyal/Kültürel Kısıtlar.....	
3.6 Sağlık/Güvenlik Kısıtları.....	
3.7 Sürdürülebilirlik Kısıtları.....	
4. Professional and Ethical Issues.....	
4.1 Üçüncü Taraf Lisansları ve Kullanım Sorumlulukları.....	
5. Requirements.....	
5.1 Fonksiyonel Gereksinimler.....	
5.2 Fonksiyonel Olmayan Gereksinimler.....	
References.....	

Introduction

1.1 Amaç

Bu projenin amacı, büyük dil modellerine dayalı çok ajanlı sistemlerde ajanlar arası iletişim katmanında ortaya çıkan uyumsuzlukları otomatik olarak tespit eden, sınıflandıran ve açıklayan entegre edilebilir LLM tabanlı bir sistem geliştirmektir. Mevcut araçların sağlayamadığı otomatik tespit ve açıklama katmanı eksikliği giderilmesi, tespit edilen her uyumsuzluğun türünün, gerçekleştiği adımın ve nedeninin anlaşılır biçimde raporlanması ve geliştiricilerin manuel olarak log incelemesine gerek kalmadan hataları hızlı ve doğru biçimde belirleyebilmesi hedeflenmektedir.

1.2 Hedef Kullanıcılar

Sistemin birincil kullanıcılarını, çok ajanlı yapay zeka sistemleri geliştiren araştırma ve geliştirme ekipleri, ajan tabanlı AI uygulamaları geliştiren yazılım mühendisleri ve farklı çok ajanlı AI mimarilerinin performans ve güvenilirliğini değerlendiren araştırmacılar oluşturmaktadır. Bu kullanıcılar geliştirilecek sistemi iletişim ve koordinasyon kaynaklı başarısızlıkları tespit etmek, hata analizi yapmak ve sistemlerini iyileştirmek amacıyla kullanacaktır.

Sistemin ikincil kullanıcılarını ise yapay zeka kalite güvence ekipleri, açıklanabilir yapay zeka alanında çalışan araştırmacılar ve çok ajanlı sistemler üzerine çalışan öğrenciler ve eğitmenler oluşturmaktadır. Bu kullanıcılar, sistemi doğrulama, performans değerlendirme, akademik araştırma ve eğitim faaliyetlerinde destekleyici bir araç olarak kullanabilecektir.

1.3 Başarı Kriterleri

Projenin başarılı kabul edilebilmesi için geliştirilen sistemin MAST veri kümesi üzerinde çalışarak çok ajanlı konuşma kayıtlarını analiz edebilmesi, iletişim ve koordinasyon kaynaklı başarısızlıkları doğru şekilde tespit edip makul bir sürede ilgili MAST kategorilerine sınıflandırabilmesi beklenmektedir. Ayrıca sistemin, her tespit edilen başarısızlık için açıklayıcı analiz üretebilmesi ve sonuçları yapılandırılmış bir formatta sunabilmesi beklenmektedir.

Başarı Kriteri 1: Hata Tespit Performansı

Sistemin, MAST veri kümesinde yer alan örnekler üzerinde gerçekleştirilen testlerde iletişim ve koordinasyon uyumsuzluklarını tespit etmede en az 0,8 F1-Skoruna olabildiğince yaklaşılması hedeflenmektedir.

Başarı Kriteri 2: Hata Türü Sınıflandırma Başarısı

Tespit edilen uyumsuzlukların ilgili hata kategorilerine doğru atanabilmesinde %75'e yakın sınıflandırma doğruluğu elde edilmesi amaçlanmaktadır.

Başarı Kriteri 3: Açıklanabilirlik Yeteneği

Sistem tarafından tespit edilen her hata için:

- Hatanın gerçekleştiği konuşma adımının belirlenmesi,
- Hata türünün raporlanması,
- Hatanın neden gerçekleştiğine dair açıklama üretilmesi

beklenmektedir. Test edilen örneklerin en az %90'ında bu bilgilerin eksiksiz şekilde sunulması hedeflenmektedir.

Başarı Kriteri 4: İşlem Süresi

Bir çok ajanlı konuşma oturumunun analiz edilmesi ve raporlanması sürecinin ortalama olarak 10 saniyenin altında tamamlanması hedeflenmektedir. Böylece sistemin gerçek zamanlı veya gerçek zamana yakın senaryolarda kullanılabilmesinin önü açılmaktadır.

Description

2.1 Sistem Tanımı ve İşleyişi

AgentLens, çok ajanlı LLM sistemlerinde ajanlar arasında gerçekleşen konuşma akışını izleyen, bu akışı standart bir veri formatına dönüştüren ve iletişim/koordinasyon kaynaklı başarısızlıkları otomatik olarak analiz eden bir hata tespit sistemidir. Sistem, mevcut çok ajanlı sistemlerin davranışlarını analiz ederek hata kaynaklarını anlaşılır hale getirmeyi amaçlamaktadır.

Sistem, ajanlar arasında gerçekleşen mesajlaşmaları, ajan rollerini, mesaj sırasını, zaman bilgisini, görev bağlamını toplar. Bu ham konuşma kayıtları önce saklanır, ardından standart bir JSON şemasına dönüştürülür. Böylece farklı kaynaklardan gelen konuşma kayıtları ortak ve analiz edilebilir bir formata getirilir.

AgentLens'in analiz süreci iki aşamalı bir yapıya sahiptir. İlk aşamada, konuşma penceresi Stage 1: Anomaly Detection Model tarafından değerlendirilir. Bu model, konuşmanın normal mi yoksa şüpheli mi olduğunu belirleyen hızlı bir ön kontrol mekanizması olarak çalışır. Şüpheli görülen konuşmalar ikinci aşamaya aktarılır. İkinci aşamada Stage 2: Failure Analysis Model, konuşmayı daha detaylı inceleyerek hatanın türünü, hangi konuşma adımında başladığını, hangi ajanlar arasında oluştuğunu ve neden meydana geldiğini belirlemeye çalışır.

Analiz sonucunda elde edilen bilgiler Report Generator modülü tarafından anlaşılır ve yapılandırılmış bir rapora dönüştürülür. Bu raporlar arayüzde kullanıcıya sunulur. Böylece araştırmacılar ve yazılım geliştiriciler, çok ajanlı LLM sistemlerinde yaşanan başarısızlıkları yalnızca sonuç düzeyinde değil, konuşma akışı ve ajanlar arası etkileşim düzeyinde inceleyebilir.

2.2 Ana Fonksiyonlar

Ajanlar arası konuşma verisini toplama:

Sistem, çok ajanlı LLM ortamlarında ajanlar arasında gerçekleşen mesajlaşmaları ve bu mesajlara ait metadata bilgilerini toplar. Bu metadata; mesajı gönderen ajan, mesajı alan ajan, mesaj sırası, zaman bilgisi, görev bağlamı bilgilerini içerebilir.

Ham veriyi saklama:

Toplanan konuşma kayıtları Raw Trace Storage içerisinde saklanır. Bu sayede ham veriler daha sonra yeniden işlenebilir, hata analizi yapılabilir ve sistemin farklı bileşenleri test edilirken geçmiş konuşmalar tekrar kullanılabilir.

Veriyi standart formata dönüştürme:

Data Formatter modülü, farklı biçimlerde gelen ham konuşma kayıtlarını ortak bir JSON şemasına dönüştürür. Bu işlem, sistemin farklı çok ajanlı LLM yapılarından gelen verileri tutarlı biçimde analiz edebilmesini sağlar.

Konuşma bağlamı oluşturma:

Conversation Window Builder, güncel mesajı önceki konuşma geçmişiyle birleştirerek analiz penceresi oluşturur. Bu yapı, sistemin yalnızca tek bir mesajı değil, mesajın önceki bağlamla ilişkisini de değerlendirmesine olanak sağlar.

Anomali tespiti yapma:

Stage 1: Anomaly Detection Model, oluşturulan konuşma penceresini değerlendirerek konuşmanın normal mi yoksa şüpheli mi olduğunu belirler. Bu aşama, hızlı ve düşük maliyetli bir ön filtreleme mekanizması olarak çalışır.

Hata türünü ve nedenini analiz etme:

Stage 2: Failure Analysis Model, şüpheli olarak işaretlenen konuşmaları MAST taksonomisine göre detaylı biçimde analiz eder. Bu aşamada hatanın türü, olduğu konuşma adımı, ilgili ajanlar ve hatanın olası nedeni belirlenir.

Rapor üretme ve kullanıcıya sunma:

Report Generator, analiz sonucunu yapılandırılmış ve okunabilir bir rapora dönüştürür. Dashboard / Logs arayüzü üzerinden kullanıcılar normal konuşma akışlarını, şüpheli durumları ve detaylı hata raporlarını inceleyebilir.

2.3 Out-of-Scope

Aşağıdaki özellikler proje kapsamı dışında bırakılmıştır:

1. Çok ajanlı sistemlerin görev yürütme sürecine doğrudan müdahale edilmesi:

AgentLens, ajanların görevleri nasıl yerine getirdiğini değiştiren veya çalışma akışına doğrudan müdahale eden bir sistem olarak tasarlanmamıştır. Sistem yalnızca gözlemleme, analiz etme ve raporlama amacı taşır.

2. Her çok ajanlı sisteme doğrudan entegre edilebilme garantisi verilmesi:

AgentLens'in, belirli ve yaygın kullanılan çok ajanlı LLM sistemlerine entegre edilebilecek modüller bir analiz katmanı olarak tasarlanması hedeflenmektedir. Bu kapsamda sistemin, desteklenen veri formatları, log yapıları ve test ortamları üzerinden çalışabilecek bir prototip olarak geliştirilmesi amaçlanmaktadır. Ancak AgentLens'in her çok ajanlı LLM mimarisine, her framework'e veya her özel log yapısına doğrudan ve sorunsuz biçimde entegre edilebileceği taahhüt edilmemektedir. Farklı veya özel tasarlanmış çok ajanlı sistemlere entegrasyon; ilgili sistemin log erişimi, mesaj formatı, ajan yapısı, kullanılan framework ve teknik kısıtlarına bağlı olarak ek uyarılma gerektirebilir. Bu nedenle proje, yaygın entegrasyon senaryolarını desteklemeyi hedeflerken tüm olası çok ajanlı sistemlerle tam uyumluluk sağlamayı kapsam dışı bırakmaktadır.

3. **Tespit edilen hataların otomatik olarak düzeltilmesi:**

Sistem, tespit ettiği hataları otomatik olarak düzeltmeyecek veya ajanlara yeni görev planı üretmeyecektir. Hata düzeltme ve ajan davranışını yeniden planlama bu projenin kapsamı dışındadır.

4. **Yeni bir çok ajanlı sistem mimarisi geliştirilmesi:**

Projenin amacı yeni bir multi-agent framework tasarlamak değildir. AgentLens, mevcut veya test amaçlı oluşturulan çok ajanlı sistemlerin üzerine eklenebilecek bir analiz ve denetleme katmanı olarak konumlandırılmıştır.

5. **İnsan-ajan etkileşimlerinden kaynaklanan hataların incelenmesi:**

Proje, özellikle ajanlar arası iletişim ve koordinasyon hatalarına odaklanmaktadır. İnsan kullanıcı ile ajan arasındaki etkileşimden doğan hatalar bu aşamada analiz kapsamına dahil edilmeyecektir.

6. **Görsel veya ses çıktısı üreten sistemlerin analizi:**

AgentLens, metin tabanlı konuşma kayıtları ve log verileri üzerinden çalışacak şekilde tasarlanmaktadır. Görsel, ses veya video çıktısı üreten sistemlerin içerik analizi bu projenin kapsamı dışındadır.

Constraints

3.1 Hukuki Kısıtlar

1. Veri toplama ve kişisel Veri kısıtı:

Projenin Data Collector modülü, çok ajanlı LLM sistemi üzerindeki mesajlaşmaları, log kayıtları üzerinden okuyarak datanın işlenmemiş halini Raw Trace Storage'a kaydeder. Bu mesajlaşmalar içerisinde kullanıcıların kişisel verileri bulunuyor olabilir.

Genel Veri Koruma Yönetmeliği (GDPR) ve 6698 Sayılı Kişisel Verilerin Korunması Kanunu (KVKK) uyarınca "Veri Minimizasyonu" yasal bir zorunluluktur. Fakat sistemin uyumsuzluk tespiti için konuşma bağlamına eksiksiz sahip olması gerekir. Bu veri toplama ve kişisel verilerin kullanılması anlamında bir kısıt oluşturmaktadır.

Çözüm önerisi: Kısıt, kurumsal mimarilerde kullanılan semantik takma adlandırma (Token Mapping/Pseudonymization) yöntemini kullanabilir. Stage 1 ve Stage 2 modüllerinde kullanılacak harici API'lere gönderilecek veriler, anlamsal etiketlerle takma adlandırılacaktır. Böylece kişisel veriler doğrudan paylaşılmadan bağlamın korunması hedeflenecektir. Ayrıca raporlama kısımlarında kişisel bilgilerin basılmayacağı şekilde bir tasarım gerçekleşmesi planlanmaktadır.

2. Otonom Ajanlarda Şeffaflık ,İzlenebilirlik ve İnsan Denetimi kısıtı:

Çok ajanlı LLM sistemleri, karar süreçlerinin çok adımlı ve ajanlar arası etkileşime dayalı olması nedeniyle kullanıcılar için çoğu zaman kara kutu benzeri bir yapı sergileyebilir.

Uluslararası yapay zeka regülasyonları ve veri otoriteleri, otomatik karar veren sistemlerde şeffaflığı sağlayabilmek adına izlenebilirlik ve insan denetimini zorunlu tutuyor. Bu sistemin gözetlenebilir olarak tasarlanması adına bir kısıt oluşturmaktadır.

Çözüm önerisi: Sistemin raporlama bileşenleri, bu şeffaflığı sağlayacak şekilde tasarlanacak. Projemizin dökümanlarında belirtildiği gibi raporlama bileşenlerinin amacı oluşan problem ve uyumsuzlukların detaylarını belirtmek üzerine kuruludur.

3.2 Etik Kısıtlar

1. Algoritmik önyargı:

Projenin Stage 2 modeli, ajanlar arası logları inceleyerek hataları etiketleyen bir yargıç (LLM-as-a-Judge) olarak çalışır. Ancak Büyük Dil Modelleri, doğası gereği belirli uzunluktaki veya kendi ürettiğine benzeyen yapıdaki cevapları kayırma (bias) eğilimi gösterir. Bu da taraflı ve hatalı etiketlemeyle sonuçlanabilir. Bu güvenilir yapay zeka etiğine bağlı olarak bir kısıt oluşturur.

Çözüm önerisi: Modelin kararlarını objektif temellere dayandırmak için MAST Store veri tabanından "Retrieval Destekli Dinamik Few-Shot Seçimi" yöntemi kullanılacaktır. Böylece model kendi önyargılarıyla serbest karar vermek yerine, uzmanlar tarafından etiketlenmiş geçmiş hataları referans olarak daha tutarlı ve izlenebilir bir tespit yapacaktır.

2. Hesap Verilebilirlik kısıtı:

Yapay zeka sistemlerinin var olmayan durumları gerçekmiş gibi üretmesi (halüsinasyon), hata tespit araçları için kritik bir etik sorundur. Sistemin, gerçekte olmayan bir hatayı raporlaması veya iletişimdeki suçu yanlış bir ajana atfetmesi, geliştiricileri yanlış yönlendireceği için algoritmik hesap verilebilirliği (accountability) zedeler.

Çözüm önerisi: Raporlama bileşenlerinin detaylı çıktıları projenin karar mekanizmasının izlenebilirliğini sağlayarak, hesap verilebilirliği sağlar.

3.3 Çevresel Kısıtlar

Yüksek Enerji Tüketimi ve Donanım Yüğü Kısıtı:

Ajan loglarının gerçek zamana yakın analizi, sunucularda (GPU/CPU) aralıksız veri işleme (inference) yükü yaratır. Akan tüm verilerin sürekli büyük dil modelleri (LLM) tarafından işlenmesi, yüksek elektrik tüketimine ve karbon emisyonuna yol açarak çevresel bir kısıt oluşturur.

Çözüm önerisi: Sistemin aşama 1 ve aşama 2 olarak tespit sistemlerini ikiye ayırması bu kısıtla bağdaştırılabilir. Yüksek enerji harcayan ağır analiz modeli (Stage 2) sadece anomali etiketli küçük veri kümelerinde çalıştırılarak sistemin genel karbon ayak izi minimize edilecektir.

3.4 Ekonomik Kısıtlar

API Maliyet ve Bütçe Kısıtı:

Sistemin Stage 1 ve Stage 2 modülleri, her konuşma penceresi için harici LLM API servislerine çağrı yapmaktadır. Bu çağrılar OpenAI veya Anthropic gibi ticari sağlayıcılar üzerinden gerçekleştirilmekte olup kullanım hacmine bağlı olarak maliyet oluşturmaktadır. Proje, öğrenci ekibi tarafından yürütüldüğünden kurumsal bütçe veya araştırma fonu desteği bulunmamaktadır. Bu durum, geliştirme ve test süreçlerinde gerçekleştirilebilecek deneme sayısını, kullanılacak model kapasitesini ve veri işleme hacmini doğrudan kısıtlamaktadır.

Çözüm önerisi: Bu kısıt, sistem mimarisinin tasarım kararlarıyla doğrudan ele alınmıştır. İki aşamalı dedektör yapısı sayesinde her konuşma adımında yalnızca düşük maliyetli Stage 1 modeli çalıştırılmakta; Stage 2 yalnızca şüpheli olarak işaretlenen az sayıda örnek için devreye girmektedir. Böylece toplam API çağrısı sayısı minimize edilmektedir. Model seçiminde GPT-4o-mini ve Claude Haiku gibi düşük maliyetli ve hızlı modeller tercih edilecektir. Geliştirme sürecinde ayrıca sağlayıcıların öğrenci ve yeni hesap ücretsiz kullanım kotalarından azami ölçüde yararlanılacaktır.

3.5 Sosyal/Kültürel Kısıtlar

Yapay Zeka Okuryazarlığı Kısıtı:

Geliştirilen sistem, büyük dil modelleri (LLM), çok ajanlı sistemler (MAS), failure mode ve anomali tespiti gibi teknik kavramlar üzerine inşa edilmiştir. Bu kavramlar henüz geniş yazılım geliştirici kitlesine yayılmamış, yalnızca belirli bir uzmanlık alanında tanınan terimlerdir. Sistemin ürettiği raporların doğru yorumlanabilmesi, kullanıcının bu kavramları önceden biliyor olmasını gerektirmektedir. Yapay zeka okuryazarlığının henüz istenilen düzeyde yaygınlaşmamış olması, sistemin potansiyel kullanıcı kitlesini daraltmakta ve benimsenmesini kısıtlamaktadır. Bu durum, aracın yalnızca MAS geliştirme deneyimine sahip araştırmacılar ve yazılım mühendisleri tarafından etkin biçimde kullanılabilmesi anlamında sosyal bir kısıt oluşturmaktadır.

3.6 Sağlık/Güvenlik Kısıtları

Yüksek Riskli Alanlarda Kullanım Kısıtı:

Geliştirilen sistem, çok ajanlı LLM sistemlerinde ajanlar arası uyumsuzlukları tespit eden ve raporlayan bir araç olarak tasarlanmıştır. Ancak bu sistemin sağlık, havacılık veya finansal sistemler gibi hata toleransının son derece düşük olduğu kritik alanlarda çalışan çok ajanlı yapılara entegre edilmesi durumunda, sistemin ürettiği raporların tek başına karar mekanizması olarak kullanılması ciddi riskler doğurabilir. Sistemin yanlış negatif üretmesi — yani gerçek bir uyumsuzluğu gözden kaçırmaması — bu tür ortamlarda telafi edilemez sonuçlara yol açabilir. Bu durum, sistemin kullanım alanını ve bağlamını kısıtlayan bir sağlık ve güvenlik kısıtı oluşturmaktadır.

Çözüm önerisi: Sistem, mevcut haliyle kritik karar mekanizmalarının yerini almak için değil, geliştirici ekiplere yardımcı bir tanı aracı olarak konumlandırılmıştır. Yüksek riskli alanlarda kullanılması durumunda sistemin çıktılarının ek insan denetimi ve doğrulama mekanizmalarıyla desteklenmesi zorunludur.

3.7 Sürdürülebilirlik Kısıtları

1. Teknik Sürdürülebilirlik Kısıtı:

Sistemde kullanılan dış LLM API'leri hizmet sağlayıcılar tarafından sürekli güncellenmekte ve eski model versiyonları kullanımdan kaldırılmaktadır. Ayrıca uyumsuzluk analizinin temelini oluşturan MAST taksonomisinin gelecekte yeni hata modlarıyla genişleme ihtimali bulunmaktadır. Bu dinamik yapı, sistemin uzun vadeli bakımını ve stabilitesini zorlaştıran bir teknik kısıttır.

Çözüm önerisi: Sistemin dış servislere olan bağımlılığının yaratacağı sorunları en aza indirmek için modüler bir mimari benimsenecektir. Çekirdek sistem ile dış servis entegrasyonları birbirinden izole edilecek; böylece API veya model değişikliklerinde tüm sistemin değil, yalnızca ilgili katmanın güncellenmesi yeterli olacaktır. Ayrıca sınıflandırma ve veri yapılarının koda sabitlenmesi (hardcoded) yerine, dışarıdan yapılandırılabilir (configurable) bir tasarım kullanılarak sistemin gelecekteki değişikliklere esnek bir şekilde uyum sağlaması hedeflenmektedir.

2. Veri Sürdürülebilirliği Kısıtı:

Modelin referans aldığı MAST veri kümesi sabit bir veri setidir. Zamanla yeni çok ajanlı framework'ler geliştirildikçe ve farklı ajan davranış kalıpları ortaya çıktıkça, bu sabit veri seti güncelliğini yitirecektir. Sistemin tespit başarısının zaman içinde düşmemesi, güncel verilerle beslenmeye devam etmesine bağlıdır.

Çözüm önerisi: sistemin veri katmanı çekirdek mimariden tamamen izole edilecektir. Referans alınacak veri seti kod tabanına gömülü olmak yerine, dışarıdan okunabilen yapılandırma dosyaları üzerinden sisteme dahil edilecektir. İlerleyen süreçte literatüre yeni veri setleri eklendiğinde, sistemde veya kodda hiçbir değişiklik yapmaya gerek kalmadan yalnızca ilgili veri dosyasının güncel versiyonuyla değiştirilmesi (manuel versiyonlama) sayesinde veri sürdürülebilirliği sağlanacaktır.

4. Professional and Ethical Issues

AgentLens projesi, çok ajanlı LLM sistemlerinde ajanlar arası konuşma akışını, log kayıtlarını ve ilgili metadata bilgilerini toplayarak anomali ve başarısızlık tespiti yapmayı amaçlamaktadır. Proje önerisinde belirtildiği üzere sistem; Data Collector, Raw Trace Storage, Data Formatter, Stage 1 Anomaly Detection, Stage 2 Failure Analysis ve Dashboard/Logs gibi bileşenlerden oluşan modüler bir analiz hattı üzerine kuruludur. Bu yapı, sistem güvenilirliği ve açıklanabilirliği açısından önemli bir katkı sağlarken; profesyonel etik, veri gizliliği, kullanıcı güvenliği ve yasal sorumluluklar açısından da dikkatli şekilde değerlendirilmelidir.

ACM Code of Ethics and Professional Conduct'a göre bilgisayar sistemleri geliştiren kişiler toplum yararını gözetmeli, olası zararı en aza indirmeli, dürüst ve güvenilir sistemler tasarlamalıdır [7]. Bu ilke doğrultusunda AgentLens'in ürettiği hata analiz raporları kullanıcıyı yanıltmayacak şekilde sunulmalıdır. Sistem, LLM tabanlı analiz modelleri kullandığı için yanlış pozitif veya yanlış negatif sonuçlar üretebilir. Bu nedenle Dashboard/Logs ekranında yalnızca bir hata tespiti sonucu vermek yerine; hatanın hangi konuşma adımıyla ortaya çıktığı, hangi ajanlar arasında gerçekleştiği, hangi hata türüne karşılık geldiği ve hangi kanıtlara dayandığı açıkça gösterilmelidir.

IEEE Code of Ethics'e göre mühendisler teknik iddialarında dürüst, gerçekçi ve mevcut verilerle desteklenebilir olmalıdır [8]. Bu nedenle AgentLens projesinde elde edilen precision, recall, F1-score ve sınıflandırma doğruluğu gibi performans metrikleri açıkça raporlanmalıdır. Ayrıca sistemin yalnızca proje kapsamında belirlenen çok ajanlı iletişim ve koordinasyon hatalarını analiz ettiği, tüm yapay zekâ hatalarını veya tüm MAS başarısızlık türlerini kapsamadığı açıkça belirtilmelidir. Avrupa Birliği Yapay Zekâ Yasası ve Güvenilir Yapay Zekâ Etik Kılavuzu da risk temelli yaklaşım, şeffaflık, insan gözetimi ve hesap verebilirlik ilkelerini vurguladığından, AgentLens çıktıları nihai karar yerine denetlenebilir destekleyici analiz olarak konumlandırılmalıdır [3], [6].

Proje kapsamında gerçek kullanıcı verisi, ajan konuşmaları, log kayıtları, zaman damgaları, görev bağlamı veya metadata toplanması durumunda KVKK ve GDPR gereklilikleri dikkate alınmalıdır. GDPR'da yer alan hukuka uygunluk, şeffaflık, amaçla sınırlılık, veri minimizasyonu ve güvenli saklama ilkeleri AgentLens için doğrudan önem taşımaktadır [1]. Benzer şekilde 6698 sayılı KVKK, kişisel verilerin işlenmesinde temel hak ve özgürlüklerin korunmasını amaçlamaktadır [2]. ICO'nun yapay zekâ ve veri koruma rehberi ile ENISA'nın veri koruma mühendisliği yaklaşımı da bu tür sistemlerde gizlilik risklerinin tasarım aşamasında ele alınmasını desteklemektedir [4], [5]. Bu nedenle sistem yalnızca analiz için gerekli olan verileri toplamalı; kullanıcı adı, e-posta, API anahtarı, kurum içi gizli bilgi veya kişisel veri içeren loglar mümkün olduğunca anonimleştirilmeli veya takma adlandırılmalıdır.

Raw Trace Storage ve Formatted Data Storage bileşenlerinde tutulan verilerin güvenliği de etik ve yasal sorumlulukların önemli bir parçasıdır. Saklanan konuşma kayıtlarına yalnızca yetkili proje üyeleri

erişilmelidir. Veriler proje amacı dışında kullanılmamalı, gereğinden uzun süre saklanmamalı ve proje sonunda açık kaynak depo paylaşılacaksa gerçek kullanıcı verisi, gizli token, API key veya kurum içi özel bilgi içermediğinden emin olunmalıdır. Bu yaklaşım, hem GDPR/KVKK uyumluluğunu destekler hem de kullanıcı güvenliğini artırır [1], [2], [5].

Üçüncü taraf yazılım ve servislerin kullanımı açısından da profesyonel sorumluluklar bulunmaktadır. AgentLens projesinde Python kütüphaneleri, veri işleme araçları, açık kaynak bileşenler ve harici LLM API servisleri kullanılabileceğinden, kullanılan her bileşenin lisans koşulları kontrol edilmelidir. Lisans gerekliliklerine uyulması, kullanılan araçların doğru şekilde belirtilmesi ve harici servislerin kullanım şartlarına uygun hareket edilmesi, ACM ve IEEE etik ilkelerinde vurgulanan dürüstlük, sorumluluk ve mesleki güvenilirlik ilkeleriyle uyumludur [7], [8]. Proje önerisinde kullanılması planlanan araçlar arasında Python, watchdog, pydantic, pandas, HuggingFace datasets, sentence-transformers, FAISS/ChromaDB, OpenAI/Anthropic SDK, jinja2, Streamlit/Dash, scikit-learn, matplotlib/seaborn, GitHub ve Google Colab yer almaktadır. Bu nedenle proje kapsamında üçüncü taraf lisans ve kullanım şartları aşağıdaki şekilde takip edilecektir.

4.1 Üçüncü Taraf Lisansları ve Kullanım Sorumlulukları

Tool / Component	Project Usage	License / Terms Consideration	Project Responsibility
Python, os, pathlib, json	Ana geliştirme ortamı ve standart dosya/veri işlemleri.	Python Software Foundation License Version 2 kapsamında değerlendirilmelidir [9].	Python lisans bildirimi korunmalı; dokümantasyon veya örnek kod kullanılırsa gerekli bildirimler ihmal edilmemelidir.
Python watchdog	Ajan loglarının izlenmesi ve dosya değişikliklerinin yakalanması.	Apache License 2.0 [10].	Yeniden dağıtım durumunda lisans metni ve gerekli telif bildirimleri korunmalıdır.
pydantic	JSON şema doğrulama ve structured data validation.	MIT License [11].	MIT lisansındaki telif ve izin bildirimi proje dokümantasyonunda korunmalıdır.
pandas	MAST verisi ve tablo bazlı veri işleme.	BSD 3-Clause License [12].	Telif bildirimi korunmalı; proje, pandas geliştiricilerinin projeyi onayladığı izlenimini vermemelidir.
HuggingFace datasets	Veri kümesi erişimi ve işleme.	Library için Apache License 2.0 [13].	Kullanılan her veri kümesinin kendi lisansı ayrıca kontrol edilmelidir; lisansı belirsiz veri açık depoda paylaşılmamalıdır.
sentence-transformers	Embedding tabanlı retrieval ve dynamic few-shot selection.	Apache License 2.0 [14].	Kütüphane lisansı korunmalı; kullanılan embedding modellerinin lisansları ayrıca incelenmelidir.
FAISS	Vector similarity search / retrieval.	MIT License [15].	FAISS projeye dahil edilirse MIT lisans bildirimi korunmalıdır.

Tool / Component	Project Usage	License / Terms Consideration	Project Responsibility
ChromaDB	Alternatif vector store / retrieval altyapısı.	Apache License 2.0 [16].	Apache 2.0 lisans gereklilikleri, özellikle NOTICE ve attribution koşulları kontrol edilmelidir.
OpenAI SDK / API	Stage 1 ve Stage 2 modelleri için harici LLM çağrıları.	OpenAI Python SDK Apache License 2.0 kapsamındadır; API kullanımı ayrıca OpenAI servis şartlarına tabidir [17], [19].	API key GitHub’a yüklenmemeli; kullanıcı/trace verileri API’ye gönderilecekse gizlilik ve veri işleme koşulları kontrol edilmelidir.
Anthropic SDK / API	Alternatif LLM modeli olarak Claude API kullanımı.	Anthropic Python SDK MIT License kapsamındadır; API kullanımı Anthropic Commercial Terms’e tabidir [18], [20].	API key gizli tutulmalı; gönderilen verilerde kişisel veri, kurum içi gizli bilgi veya hassas içerik bulunmamalıdır.
instructor	LLM çıktılarının JSON/structured output formatına uygunluğunu destekleme.	MIT License [21].	Lisans bildirimi korunmalı; pydantic gibi bağımlılıklarının lisansları da dependency listesine eklenmelidir.
jinja2	Report Generator için şablon tabanlı rapor üretimi.	BSD 3-Clause License [22].	Lisans ve telif bildirimi korunmalı; şablonların telif durumu ayrıca kontrol edilmelidir.
Streamlit / Dash	Dashboard / Logs arayüzünün geliştirilmesi.	Streamlit Apache License 2.0; Dash MIT License kapsamındadır [23], [24].	Seçilen dashboard aracının lisansı dokümanite edilmeli; dashboard public deploy edilirse veri gizliliği ayrıca kontrol edilmelidir.
scikit-learn	Precision, recall, F1-score ve confusion matrix hesaplama.	BSD 3-Clause License [25].	Lisans bildirimi korunmalı; değerlendirme sonuçları dürüst ve abartsız şekilde raporlanmalıdır.
matplotlib / seaborn	Performans metriklerinin ve deney sonuçlarının görselleştirilmesi.	Matplotlib BSD-compatible/PSF-based lisans; seaborn BSD 3-Clause License kapsamındadır [26], [27].	Üretilen grafikler raporda kullanılabilir; ancak kullanılan kütüphaneler üçüncü taraf acknowledgement bölümünde belirtilmelidir.

Bu tablo doğrultusunda, proje sonunda açık kaynak depo paylaşılmadan önce tüm doğrudan bağımlılıklar, veri setleri, harici API servisleri ve geliştirme platformları kontrol edilmelidir. Repository içerisinde LICENSE, README veya ayrı bir THIRD_PARTY_NOTICES bölümü oluşturularak kullanılan üçüncü taraf araçlar ve lisansları açıkça belirtilmelidir. Bu yaklaşım, hem fikri mülkiyet haklarına saygı gösterilmesini sağlar hem de ACM/IEEE etik ilkeleriyle uyumlu, şeffaf ve profesyonel bir yazılım geliştirme süreci yürütülmesine katkı sağlar [7], [8].

Sonuç olarak AgentLens projesinde etik sorumluluk yalnızca çalışan bir anomali tespit sistemi geliştirmekle sınırlı değildir. Proje ekibi; sistemi güvenilir, açıklanabilir, gizliliğe duyarlı, yasal düzenlemelere uygun ve kullanıcıyı yanıltmayacak şekilde tasarlamaktan sorumludur. Bu ilkeler doğrultusunda geliştirilecek AgentLens,

çok ajanlı LLM sistemlerinin teknik analizine katkı sağlarken aynı zamanda profesyonel ve etik yazılım mühendisliği yaklaşımına uygun bir proje çıktısı sunacaktır.

5. Requirements

Bu bölümde AgentLens sisteminin karşılaması gereken fonksiyonel ve fonksiyonel olmayan gereksinimler listelenmiştir. Fonksiyonel gereksinimler sistemin hangi işlevleri yerine getireceğini, fonksiyonel olmayan gereksinimler ise bu işlevlerin hangi ölçülebilir kalite kriterlerine göre değerlendirileceğini tanımlar.

5.1 Fonksiyonel Gereksinimler

FR-1 (Veri Toplama): Data Collector, izlenen çok ajanlı LLM sisteminden ajanlar arası mesajları, log kayıtlarını ve ilgili metadata'yı (gönderen ajan, alıcı ajan, tur sırası, zaman damgası, araç çağrısı bilgisi, gerçekleştirilen aksiyon, görev bağlamı) yakalamalıdır.

FR-2 (Ham Veri Saklama): Sistem, toplanan ham veriyi işlenmemiş haliyle Raw Trace Storage içinde saklamalı ve gerektiğinde yeniden işlenebilmesine olanak tanımalıdır.

FR-3 (Veri Formatlama): Data Formatter, farklı kaynaklardan gelen ham trace verisini ortak ve standart bir JSON konuşma şemasına (ajan adları, roller, mesaj içeriği, konuşma sırası, global görev, araç çağrısı, aksiyon detayları) dönüştürmelidir.

FR-4 (Formatlı Veri Saklama): Sistem, formatlanmış konuşma verisini Formatted Data Storage içinde saklamalı ve Conversation Window Builder tarafından okunabilir kılmalıdır.

FR-5 (Bağlam Penceresi Oluşturma): Conversation Window Builder, güncel mesajı birikmiş konuşma geçmişleriyle birleştirerek bağlama duyarlı bir analiz penceresi üretmelidir.

FR-6 (Anomali Tespiti): Stage 1: Anomaly Detection modeli, her analiz penceresini few-shot prompting yöntemiyle normal/şüpheli olarak ikili sınıflandırmalıdır.

FR-7 (Anomali Skoru): Stage 1, kararına dair güven seviyesini gösteren bir anomali skoru üretmelidir.

FR-8 (Normal Akış Yönlendirme): Normal olarak etiketlenen pencereler doğrudan Dashboard/Logs bileşenine iletilmelidir.

FR-9 (Şüpheli Akış Yönlendirme): Şüpheli olarak etiketlenen pencereler ileri analiz için Stage 2'ye iletilmelidir.

FR-10 (Dinamik Few-Shot Retrieval): Stage 2, MAST Store'dan embedding tabanlı retrieval ile o vakaya anlamsal olarak en yakın örnekleri dinamik olarak seçmeli ve prompt'una few-shot örnek olarak eklemelidir.

FR-11 (Hata Analizi): Stage 2: Failure Analysis modeli, her şüpheli pencere için hatanın türünü (ilgili MAST kategorisi), hatanın başladığı konuşma adımını, hataya dahil olan ajanları ve hatanın nedenini belirlemelidir.

FR-12 (Rapor Üretimi): Report Generator, Stage 2 çıktısını hem insan hem de diğer sistemler tarafından işlenebilir, yapılandırılmış (structured output) bir rapor formatına dönüştürmelidir.

FR-13 (Görselleştirme ve Loglama): Dashboard/Logs bileşeni, normal etiketlenen konuşmaları, tespit edilen hataları ve üretilen raporları kullanıcıya görüntüleyebilmelidir.

FR-14 (Sentetik Veri Üretimi): Sistem, MAST veri kümesinin yetersiz kaldığı senaryolarda manuel veya yarı otomatik olarak oluşturulan etiketli sentetik konuşma örneklerinin sisteme dahil edilmesini desteklemelidir.

FR-15 (Performans Değerlendirme): Sistem, MAST veri kümesi üzerinde precision, recall, F1-skoru, accuracy ve confusion matrix metriklerini hesaplayabilmelidir.

FR-16 (Gizlilik ve Takma Adlandırma): Sistem, harici LLM API'lerine veri göndermeden önce kişisel verileri takma adlandırma (token mapping/pseudonymization) ve üretilen raporlarda kişisel bilgilere yer vermemeyi desteklemelidir.

5.2 Fonksiyonel Olmayan Gereksinimler

Performans

NFR-1 (Oturma İşlem Süresi): Belirlenen maksimum konuşma penceresi boyutu için uçtan uca analiz ve raporlama süreci ortalama 10 saniyenin altında tamamlanmalıdır.

NFR-2 (Yerel İşleme Gecikmesi): Data Formatter ve Conversation Window Builder modüllerinin yerel işleme gecikmesi (harici LLM çağrılarını hariç) $p95 < 500$ ms olmalıdır.

Doğruluk ve Kalite

NFR-3 (Tespit Başarımı): Sistem, MAST veri kümesindeki iletişim ve koordinasyon uyumsuzluklarını tespit etmede en az 0,80 F1-skoru elde etmelidir.

NFR-4 (Sınıflandırma Doğruluğu): Tespit edilen uyumsuzlukların doğru hata kategorisine atanmasında en az %75 sınıflandırma doğruluğu sağlanmalıdır.

NFR-5 (Açıklanabilirlik Tamlığı): Test edilen örneklerin en az %90'ında üretilen rapor; hatanın gerçekleştiği adımı, hata türünü ve nedene dair açıklamayı eksiksiz içermelidir.

NFR-6 (Yüksek Recall Önceliği): Stage 1, kaçırılan anomali (false negative) oranını en aza indirmek için yüksek recall önceliğiyle çalışmalı ve recall değeri MAST referans değerlerine olabildiğince yaklaşmalıdır.

Modülerlik ve Bakım

NFR-7 (Modülerlik): Her modül tek bir sorumluluğa sahip olmalı, tanımlı input/output arayüzleri üzerinden bağımsız olarak değiştirilebilmeli ve bir bileşendeki değişiklik diğerlerini etkilememelidir.

Taşımaabilirlik ve Entegrasyon

NFR-8 (Dışarıdan Bağlanabilirlik): Sistem, izlenen çok ajanlı sistemi değiştirmeden log kayıtları üzerinden çalışmalı; ayrıca JSON/JSONL formatındaki konuşma kayıtlarını kabul ederek offline analiz yapabilmelidir.

NFR-9 (Genişletilebilir Şema): Veri şeması minimum zorunlu alanlardan oluşmalı, ek alanlar opsiyonel olmalıdır; böylece farklı framework'lerden gelen ve yalnızca temel alanları içeren veriler de analiz edilebilmelidir.

Güvenlik ve Gizlilik

NFR-10 (Erişim ve Veri Koruma): Raw Trace Storage ve Formatted Data Storage içindeki verilere yalnızca yetkili proje üyeleri erişebilmeli; açık kaynak depo paylaşılmadan önce veriler gerçek kullanıcı verisi, API anahtarı veya kurum içi gizli bilgi içermemelidir.

NFR-11 (Anahtar Yönetimi): API anahtarları environment variable veya secret management mekanizması üzerinden yönetilmeli, .env dosyaları .gitignore kapsamına alınmalıdır.

Güvenilirlik

NFR-12 (Yeniden İşleme): Formatlama veya pipeline aşamasında bir hata oluştuğunda sistem, ilgili konuşmaları Raw Trace Storage üzerinden yeniden işleyebilmelidir.

NFR-13 (Veri Bütünlüğü): Sistem, zorunlu alanları (gönderen, alıcı, zaman damgası, tur sırası) doğrulamalı ve eksik veri durumunda uyarı üretmelidir.

Verimlilik ve Çevresel Etki

NFR-14 (Maliyet/Enerji Optimizasyonu): Yüksek maliyetli Stage 2 modeli yalnızca anomali etiketli pencerelerde çalıştırılarak işlem maliyeti ve karbon ayak izi minimize edilmelidir.

Kullanılabilirlik

NFR-15 (İşlenebilir Çıktı): Üretilen raporlar structured output (JSON) formatında olmalı; hem insanlar hem de dış sistemler tarafından işlenebilmelidir.

References

- [1] European Union, "Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data (General Data Protection Regulation)," Official Journal of the European Union, L 119, pp. 1-88, May 2016.
- [2] T.C. Yasama Organı, "Kişisel Verilerin Korunması Kanunu," Kanun No. 6698, T.C. Resmî Gazete, Sayı: 29677, 7 Nisan 2016.
- [3] European Parliament and Council, "Regulation laying down harmonised rules on Artificial Intelligence (Artificial Intelligence Act)," Official Journal of the European Union, 2024.
- [4] Information Commissioner's Office (ICO), "Guidance on AI and Data Protection," ICO Publications, 2023. [Online]. Available: <https://ico.org.uk/>.
- [5] European Union Agency for Cybersecurity (ENISA), "Data Protection Engineering," ENISA Reports, Nov. 2022.
- [6] High-Level Expert Group on Artificial Intelligence, "Ethics Guidelines for Trustworthy AI," European Commission, Apr. 2019.
- [7] Association for Computing Machinery, "ACM Code of Ethics and Professional Conduct," ACM, 2018. [Online]. Available: <https://www.acm.org/code-of-ethics>. Accessed: Jun. 28, 2026.

- [8] IEEE, "Ethical Guidelines & Policies: IEEE Code of Ethics," IEEE. [Online]. Available: <https://events.ieee.org/planning-basics/general-guidelines/ethical-guidelines-and-policies/>. Accessed: Jun. 28, 2026.
- [9] Python Software Foundation, "History and License — Python Documentation." [Online]. Available: <https://docs.python.org/3/license.html>. Accessed: Jun. 28, 2026.
- [10] The watchdog Authors, "watchdog License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/gorakhargosh/watchdog/master/LICENSE>. Accessed: Jun. 28, 2026.
- [11] Pydantic Services Inc., "pydantic License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/pydantic/pydantic/main/LICENSE>. Accessed: Jun. 28, 2026.
- [12] The pandas development team, "pandas License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/pandas-dev/pandas/main/LICENSE>. Accessed: Jun. 28, 2026.
- [13] Hugging Face, "datasets License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/huggingface/datasets/main/LICENSE>. Accessed: Jun. 28, 2026.
- [14] UKPLab, "sentence-transformers License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/UKPLab/sentence-transformers/master/LICENSE>. Accessed: Jun. 28, 2026.
- [15] Meta AI, "FAISS License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/facebookresearch/faiss/main/LICENSE>. Accessed: Jun. 28, 2026.
- [16] Chroma, "Chroma License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/chroma-core/chroma/main/LICENSE>. Accessed: Jun. 28, 2026.
- [17] OpenAI, "openai-python License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/openai/openai-python/main/LICENSE>. Accessed: Jun. 28, 2026.
- [18] Anthropic, "anthropic-sdk-python License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/anthropics/anthropic-sdk-python/main/LICENSE>. Accessed: Jun. 28, 2026.
- [19] OpenAI, "OpenAI Services Agreement." [Online]. Available: <https://openai.com/policies/services-agreement/>. Accessed: Jun. 28, 2026.
- [20] Anthropic, "Commercial Terms of Service." [Online]. Available: <https://www.anthropic.com/legal/commercial-terms>. Accessed: Jun. 28, 2026.
- [21] 567 Labs, "instructor License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/567-labs/instructor/main/LICENSE>. Accessed: Jun. 28, 2026.
- [22] Pallets Projects, "Jinja License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/pallets/jinja/main/LICENSE.txt>. Accessed: Jun. 28, 2026.
- [23] Streamlit, "Streamlit License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/streamlit/streamlit/develop/LICENSE>. Accessed: Jun. 28, 2026.
- [24] Plotly Technologies Inc., "Dash License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/plotly/dash/dev/LICENSE>. Accessed: Jun. 28, 2026.
- [25] scikit-learn developers, "scikit-learn License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/scikit-learn/scikit-learn/main/COPYING>. Accessed: Jun. 28, 2026.
- [26] Matplotlib Development Team, "License — Matplotlib Documentation." [Online]. Available: <https://matplotlib.org/stable/project/license.html>. Accessed: Jun. 28, 2026.

- [27] M. Waskom, "seaborn License," GitHub repository. [Online]. Available: <https://raw.githubusercontent.com/mwaskom/seaborn/master/LICENSE.md>. Accessed: Jun. 28, 2026.
- [28] M. Cemri, M. Z. Pan, S. Yang, L. A. Agrawal, B. Chopra, R. Tiwari, et al., "Why do multi-agent LLM systems fail?," *arXiv preprint arXiv:2503.13657v3*, 2025.